

FAKULTÄT FÜR MATHEMATIK, INFORMATIK UND STATISTIK INSTITUT FÜR INFORMATIK

LEHRSTUHL FÜR DATENBANKSYSTEME UND DATA MINING

Kapitel 1: Grundlagen

Algorithmen Basics

Datenstrukturen Basics



Probleme in der Informatik

- Ein Problem (im Sinne der Informatik):
 - Enthält eine Beschreibung der Eingabe
 - Enthält eine davon abhängige Ausgabe
 - Gibt <u>keinen</u> Übergang von Eingabe zu Ausgabe an

Eingabe
$$x \in \mathbb{R}^+$$
 Ausgabe $y = \sqrt{x} \in \mathbb{R}$

- Beispiele:
 - Sortiere eine Menge von Wörtern
 - Berechne die Quadratwurzel von x
 - Finde den kürzesten Pfad zwischen 2 Orten

Probleminstanzen

 Eine <u>Probleminstanz</u> ist eine konkrete Eingabebelegung, für die die entsprechende Ausgabe gewünscht ist.



- Beispiele für Probleminstanzen:
 - Sortiere folgende Wörter alphabetisch:
 [Haus, Auto, Baum, Tier, Mensch]
 - Berechne $x = \sqrt{204}$
 - Was ist der kürzeste Weg vom Hörsaal in die Mensa?

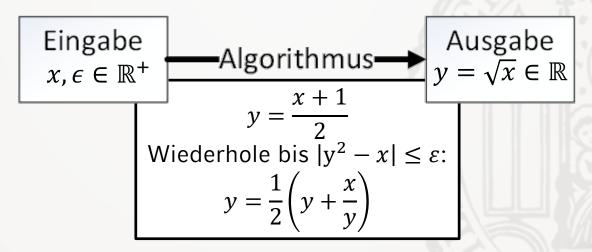
Zentraler Begriff Algorithmus

"Ein *Algorithmus* ist eine **endliche Sequenz** von Handlungsvorschriften, die eine **Eingabe** in eine **Ausgabe** transformiert."

Cormen et al., 2009

Anforderungen an Algorithmen

- Spezifizierung der Eingabe/Ausgabe:
 - Anzahl und Typen aller Elemente ist definiert.
- Eindeutigkeit:
 - Jeder Einzelschritt ist klar definiert und ausführbar.
 - Die Reihenfolge der Einzelschritte ist festgelegt.
- Endlichkeit:
 - Die Notation hat eine endliche Länge.



Beispiel SummeBis(n) in natürlicher Sprache

- Problem:
 - Für ein gegebenes $n \in \mathbb{N}$, berechne die Summe $1 + 2 + \cdots + n$
- Natürliche Sprache:
 - Initialisiere eine Variable summe mit Wert 0. Durchlaufe die Zahlen von 1 bis n mit einer weiteren Variable zähler. Addiere zähler jeweils zu summe. Gib nach dem Durchlauf den Text "Die Summe ist:" und den Wert von summe aus.

Beispiel SummeBis(n) in Pseudocode

- Problem:
 - Für ein gegebenes $n \in \mathbb{N}$, berechne die Summe $1 + 2 + \cdots + n$
- Pseudocode:

```
Setze summe = 0
```

Setze $z\ddot{a}hler = 1$

Solange **zähler** $\leq n$

setze **summe** = **summe** + **zähler**

erhöhe zähler um 1

Gib aus: "Die Summe ist:" und summe

Beispiel SummeBis(n) in Javacode

- Problem:
 - Für ein gegebenes $n \in \mathbb{N}$, berechne die Summe $1 + 2 + \cdots + n$

Java:

```
class SummeBis {
  public static void main (String[] arg) {
    int n = Integer.parseInt(arg[0]);
    int sum = 0;
    for (int i = 1; i <= n; ++i)
        sum += i;
    System.out.println ("Die Summe ist " + sum);
  }
}</pre>
```

Einige Eigenschaften von Algorithmen

- Allgemeinheit:
 - Lösung für Problemklasse, nicht für Einzelaufgabe
- Determiniertheit:
 - Für die gleiche Eingabe wird stets die gleiche Ausgabe berechnet (aber andere Zwischenzustände möglich).
- Determinismus:
 - Für die gleiche Eingabe ist die Ausführung und die Ausgabe stets identisch.
- Terminierung:
 - Der Algorithmus läuft für jede Eingabe nur endlich lange
- (partielle) Korrektheit:
 - Algorithmus berechnet stets die spezifizierte Ausgabe (falls er terminiert)
- Effizienz:
 - Sparsamkeit im Ressourcenverbrauch (Zeit, Speicher, Energie, ...)

Lernziele der Vorlesung (Algorithmen)

Nach dieser Vorlesung können Sie:

- Viele Probleme analysieren und strukturieren
- Für einige Problemklassen den passenden Algorithmus auswählen
- Algorithmen auf Probleminstanzen anwenden
- Den Rechenaufwand eines Algorithmus quantifizieren
- Die Effizienz und Anwendbarkeit mehrerer Algorithmen miteinander vergleichen

Zentraler Begriff Datenstruktur

"Eine *Datenstruktur* ist ein Weg, Daten zu **speichern** und zu **organisieren**, so dass **Zugriffe** und **Modifikationen** darauf ermöglicht werden."

Cormen et al., 2009

Datenstrukturen

- Datenstrukturen
 - Organisationsformen f
 ür Daten
 - Funktionale Sicht: Containerobjekte mit Operationen, lassen sich als abstrakte Datentypen beschreiben.
 - Beinhalten Strukturbestandteile und Nutzerdaten (Payload)
 - Können gleichförmig oder heterogen strukturiert sein
 - Anforderungen:
 - Statisch oder dynamisch bestimmte Größe
 - Transiente oder persistente Speicherung
- Betrachtete Beispiele
 - Sequenzen: Arrays, Listen, Kellerspeicher, Warteschlangen
 - Multidimensional: Matrizen
 - Topologische Strukturen: Bäume, Graphen, Netzwerke

Lernziele der Vorlesung (Datenstrukturen)

Nach dieser Vorlesung können Sie:

- Grundlegende Datenstrukturen erkennen.
- Zugehörige Basisoperationen auf Strukturen anwenden.
- Die Laufzeiten eines Algorithmus mit verschiedenen Datenstrukturen abschätzen.
- Eine geeignete Datenstruktur für eine Lösungsstrategie auswählen.
- Ähnliche Datenstrukturen miteinander vergleichen.

Datentypen

- Definition: Menge von Werten und Operationen auf diesen Werten
- Elementare (atomare) Datentypen: (Java)
 - Ganze Zahlen: byte (8-bit), short (16-bit), int (32-bit), long (64-bit)
 - Binärer Wahrheitswert (true oder false): boolean (VM-abhängig)
 - Zeichen: char (16-bit)
 - Fließkommazahlen: float (32-bit), double (64-bit)
- Zusammengesetzte Typen:
 - String: Zeichenkette
 - Record: Datensatz (in Java nicht explizit; als Objekt o.ä.)
 - Set: Menge (in Java vordefiniert, inklusive Methoden zum Sortieren etc.)
 - Array: Reihung fester Länge von gleichartigen Daten

Objektverweise als Zeiger (Pointer)

- In Java nicht explizit
- Referenz auf ein anderes Objekt
- Besteht aus Speicheradresse des referenzierten Objekts

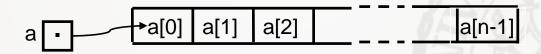


- Für dynamische Datenstrukturen: Speicher erst bei Bedarf
- In einigen Programmiersprachen explizite Speicherfreigabe
- Java hat garbage collection:
 Falls keine Referenz mehr vorhanden ist, wird der Speicher freigegeben

Zusammengesetzte Typen: Arrays

- Array: Reihung (Feld) fester Länge von Daten gleichen Typs
 - z.B. a[i] bedeutet Zugriff auf das (i + 1)-te Element eines Arrays a[]
 - Erlaubt effizienten Zugriff auf Elemente: konstanter Aufwand
 - Wichtig: Array-Grenzen beachten!

Referenz-Typ: Verweis auf (Adresse der) Daten



Vorsicht: Array a beginnt in Java bei 0 und geht bis a.length – 1!
 (Häufige Fehlerquelle)

Beispiel: Sieb des Eratosthenes

- Eratosthenes: (hellenischer Gelehrter, ca. 276–195 v. Chr.)
 - Problem: Suche alle Primzahlen kleiner n
 - Idee: Arrayelemente effizient zugreifbar

$$a[i] = \begin{cases} 1, & \text{falls } i \text{ prim ist} \\ 0, & \text{sonst} \end{cases}$$

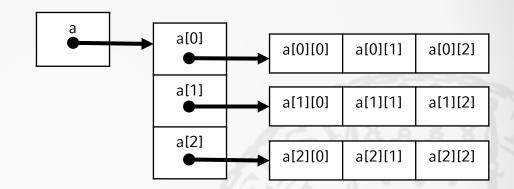
- Algorithmus:
 - Initialisiere Array-Werte bis n mit 1
 - Setze Vielfache sukzessive auf 0
 - Arrayeinträge sind nun 1, falls ihre Indizes prim sind
- Beispiel für n = 25:

i	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25
	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1	1
2			0		0		0		0		0		0		0	Ъ.	0		0		0	?	0	
3								0						0		J			1	0	1//			V)/
5																_	84	<u></u>		\mathbb{M}	10			0

Mehrdimensionale Arrays

Zweidimensionale Arrays (= Matrizen) sind Arrays von Arrays

a[0][0]	a[0][1]	a[0][2]				
a[1][0]	a[1][1]	a[1][2]				
a[2][0]	a[2][1]	a[2][2]				



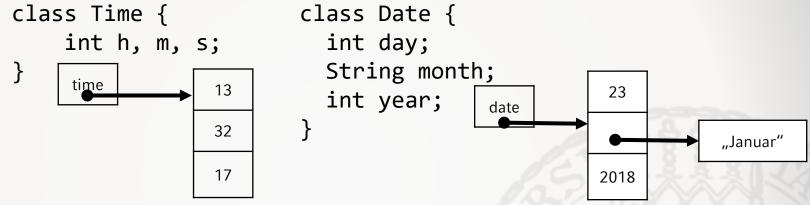
Deklaration

Höhere Dimensionen

```
int [][][] q = new int [2][2][2]; // 3D: Quader, Tensor
```

Benutzerdefinierte Datentypen: Klassen

Zusammenfassung verschiedener Attribute zu einem Objekt



- Beispiel: Rückgabe mehrerer Funktionsergebnisse auf einmal
 - Java erlaubt nur einen einzigen Rückgabewert
 - Lösung: Rückgabe eines komplexen Ergebnisobjekts

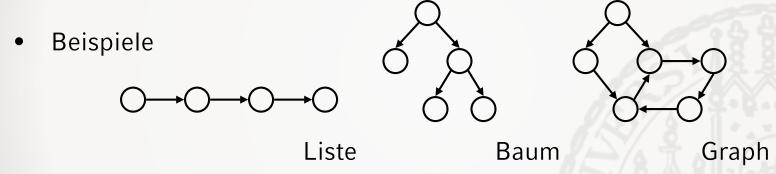
```
static Time convert (int sec) {
    Time t = new Time();
    t.h = sec / 3600; t.m = (sec % 3600) / 60; t.s = sec % 60;
    return t;
}
```

Heterogene vs. Homogene Daten

- Klassen eignen sich zur Speicherung von heterogenen Datentypen
 - Bestehen im allgemeinen aus verschiedenartigen Elementen: class c {String s; int i;}
 - Jedes Element hat einen eigenen Namen: c.s, c.i
 - Anzahl der Elemente wird statisch bei der Deklaration der Klasse festgelegt.
- Arrays ermöglichen schnellen Zugriff auf homogene Daten
 - Bestehen immer aus mehreren gleichartigen Elementen: int[]
 - Elemente haben keine eigenen Namen, sondern werden über Indizes angesprochen: a[i]
 - Anzahl der Elemente wird dynamisch bei der Erzeugung des Arrays festgelegt: new int[n]

Dynamische Datenstrukturen

- Motivation
 - Länge eines Arrays nach der Erzeugung festgelegt
 - hilfreich wären unbeschränkt große Datenstrukturen
 - Lösungsidee: Verkettung einzelner Objekte zu größeren Strukturen

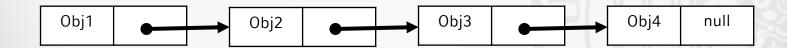


- Charakterisierung
 - Knoten zur Laufzeit (dynamisch) erzeugt und verkettet
 - Strukturen können dynamisch wachsen und schrumpfen
 - Größe einer Struktur nur durch verfügbaren Speicherplatz beschränkt; muss nicht im vorhinein bestimmt werden.

Listen

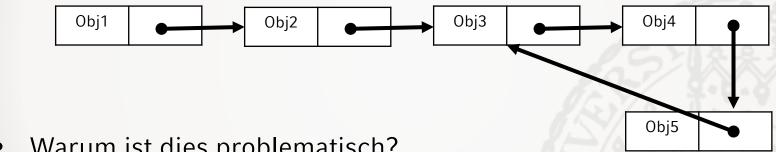
- Rekursive Struktur:
 - Liste L = head(L) o tail(L) = value o next
 - Beispiel: $\{1,2,3,4\} = \{1\} \circ \{2,3,4\}$
- Als Implementierung in Java:

```
class List {
    Object value;
    List next;
}
```



Zykelfreiheit

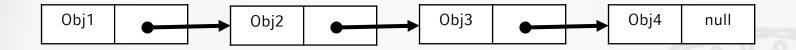
Implementierungen von Liste erlauben keine Konstruktion von Zykeln (Kreisen) innerhalb der Liste



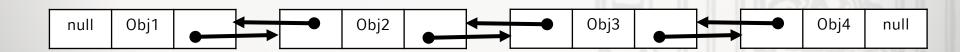
- Warum ist dies problematisch?
 - Was ist die Länge dieser Liste?
 - Wo ist das Ende?
 - Wie füge ich weitere Elemente hinten an?

Listen - Verkettung

- Einfach verkettete Liste
 - Jeder Knoten enthält Verweis auf nächsten Knoten

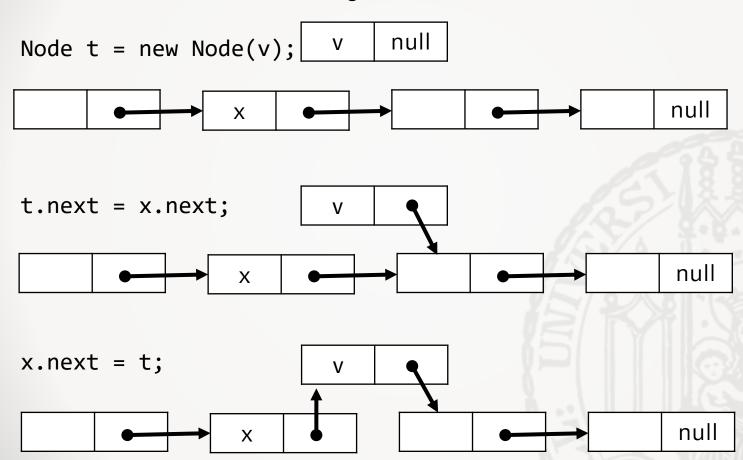


- Doppelt verkettete Liste
 - Jeder Knoten enthält zusätzlich Verweis auf vorherigen Knoten



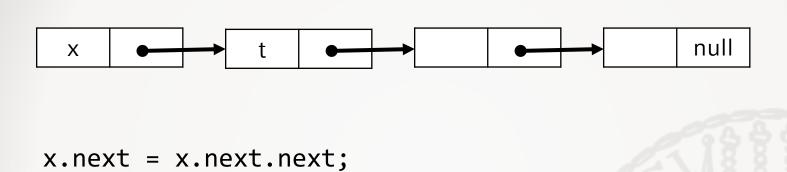
Listen - Einfügen

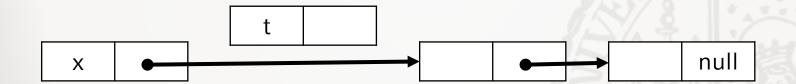
Wert v nach Knoten x einfügen



Listen - Löschen

Knoten t nach Knoten x löschen





Abstrakte Datentypen

- Datenstruktur definiert durch auf ihr zugelassener Methoden
- Spezielle Implementierung nicht betrachtet
- Definition über:
 - Menge von Objekten
 - Methoden auf diesen Objekten → Syntax des Datentyps
 - Axiome → Semantik des Datentyps
- Top-down Software-Entwurf
- Spezifikation
 - Zuerst "was" festlegen, noch nicht "wie"
 - Spezifikation vs. Implementierung
 - Klarere Darstellung von Programmkonzepten
- Abstraktion in Java:
 - Abstract class
 - Interface

Beispiel: Algebraische Spezifikation Boolean

- Wertebereich:
 - {true, false}
- Operationen:
 - NOT (Zeichen \neg): boolean → boolean
 - AND (Zeichen \wedge): boolean \times boolean \rightarrow boolean
 - OR (Zeichen \vee): boolean \times boolean \rightarrow boolean
- Axiome:
 - ¬ true = false; ¬false = true;
 - x ∧ true = x; x ∧ false = false;
 - $x \lor true = true; x \lor false = x;$

a	b	–a	a∧b	a∨b
0	0	1	0	0
0	1	1	0	1
1	0	0	0	1
1	1	0	1	1

Stacks

- Stapel von Elementen ("Kellerspeicher")
- Wie Liste: sequentielle Ordnung, aber nur Zugriff auf erstes Element:

Für Stack s und Object o gilt also:

```
s.push(o);
s.pop() == o
```

Algebraische Spezifikation Stack

Operationen:

- Init: \rightarrow Stack

- Empty: Stack \rightarrow Boolean

– Push: Element × Stack → Stack

– Pop: Stack → Element × Stack

- Axiome: Für alle Elementtyp x, Stack s gelten folgende Geleichungen:
 - Pop(Push(x,s)) = (x,s)
 - Push(Pop(s)) = s für Empty(s) = FALSE
 - Empty(Init) = TRUE
 - Empty(Push(x,s)) = FALSE
- Undefinierte Operationen erfordern Fehlerbehandlung
 - Beispiel: Pop (Init)

Stacks in Java mit Array

```
Class StackArray implements Stack
                                         Object pop () {
                                           if (top == 0) {
  int top;
                                             //Fehlerbehandlung Unterlauf
  Object[] stack;
                                             return null;
                                           } else {
  StackArray (int capacity) {
                                             top = top - 1;
   top = 0;
                                             return stack[top];
    stack = new Object[capacity];
  }
  void push (Object v) {
                                         boolean isEmpty () {
    if(top >= stack.length) {
                                           return (top == 0);
      //Fehlerbehandlung Überlauf
      return;
    } else {
                                         boolean isFull () {
      stack[top] = v;
                                           return (top >= stack.length);
      top = top + 1;
                                       } // class StackArray
```

Stacks in Java mit Listen und Pointern

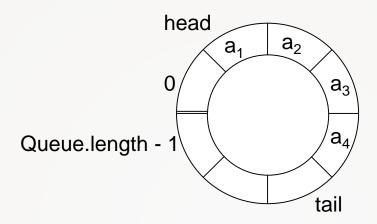
```
Class StackList implements Stack {
                                        Object pop () {
                                           if(stack == null) {
  List stack;
                                             //Fehlerbehandlung Unterlauf
                                             return null;
  StackList () {
    stack = null;
                                           } else {
                                             Object x = stack.value;
                                             stack = stack.next;
  void push (Object v) {
                                             return x;
    stack = new List();
    stack.value = v;
    stack.next = first;
                                         boolean isEmpty () {
    first = stack;
                                           return (stack == null);
                                       } // class StackList
```

Queues

- Spezifikation
 - Wie Liste: sequentielle Ordnung, aber:
 - Einfügen: neues Element am Ende anhängen (add)
 - Auslesen: vorderstes Element zurückgeben (remove)
 - FIFO (First-In-First-Out)

```
- In Java:
   interface Queue {
     void add (Object);
     Object remove();
     boolean isEmpty();
}
```

Queues als zyklisches Array



- Implementierung als zyklisches Array:
 - kein Speicher für Pointer nötig
 - leere Elemente (Speicherplatzverlust)
 - Beschränkte Länge

Queues in Java mit Array

```
class QueueArray implements Queue {
                                       Object remove () {
 int first, last;
                                        if (first == last) {
Object[] queue;
                                         //Fehlerbehandlung Unterlauf
                                         return null;
QueueArray (int capacity) {
                                        } else {
 first = 0;
                                         Object x = queue.first;
 last = 0;
                                         first = (first+1) % queue.length;
 queue = new Object[capacity+1];
                                         return x;
void add (Object v) {
 int next = (last+1) % queue.length;
  if (next == first) {
                                       boolean isEmpty () {
  // Fehlerbehandlung Überlauf
                                           return (first == last);
  return null;
  } else {
  queue[last] = v;
                                        boolean isFull () {
   last = next;
                                           return (first == (last+1) %
                                                            queue.length);
                                       } // class QueueArray
```

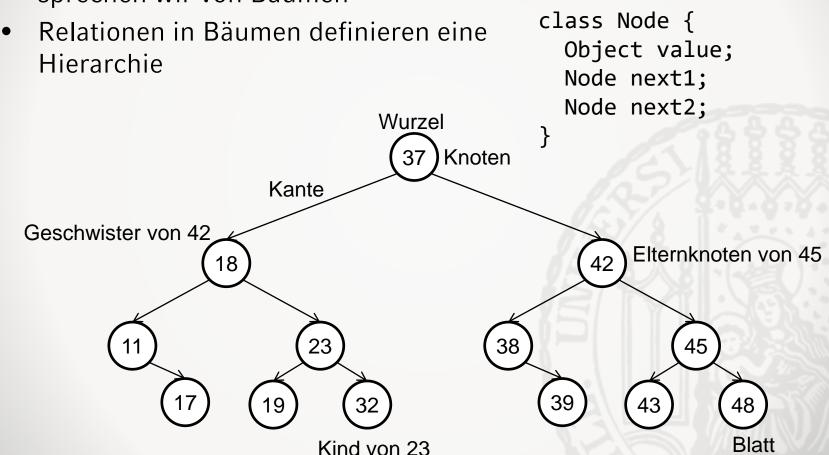
Queues in Java mit Listen

```
class QueueList implements Queue {
List first, last;
QueueList () {
 first = null;
 last = null;
void add (Object v) {
  List list = new List();
  list.value = v;
  last.next = list;
  last = list;
```

```
Object remove () {
  if (first == last) {
  //Fehlerbehandlung Unterlauf
  return null;
  } else {
  Object x = first.value;
  first = first.next;
  return x;
boolean isEmpty () {
  return (first == last);
} // class QueueList
```

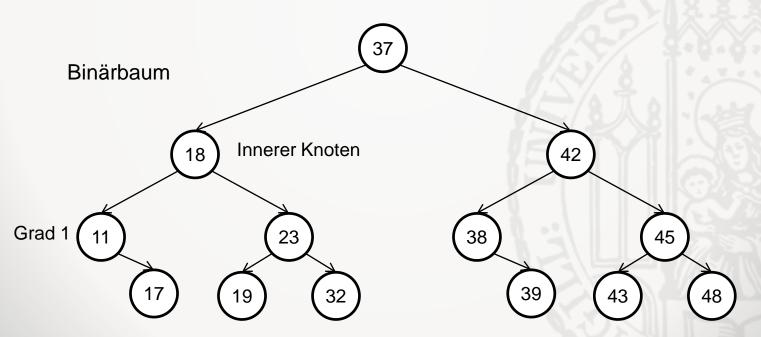
Bäume

 Erweitern wir das Listenkonzept und erlauben mehrere Nachfolger, sprechen wir von Bäumen



Terminologie von Bäumen

- Pfad: Folge von Knoten, die durch Kanten direkt verbunden sind
- Pfadlänge: Anzahl der Kanten eines Pfades
- Knotengrad: Anzahl der unmittelbaren Nachfolger eines Knotens
- Arität: Maximaler Knotengrad aller Knoten
 - Baum mit Arität 2 ist ein Binärbaum



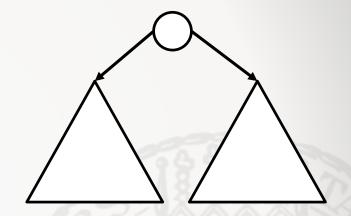
Eigenschaften von Bäumen

- Kantenmaximalität: Ein Baum mit n Knoten hat genau n Kanten.
 - Entfernt man eine Kante, ist der Baum nicht mehr zusammenhängend.
 - Fügt man eine Kante hinzu, so ist der Baum nicht mehr zykelfrei.
- Vollständiger Baum: Hat jeder Knoten den maximalen Grad, so spricht man von einem vollständigen Baum.
- Die Höhe eines Baums ist die Pfadlänge des längsten Pfads von der Wurzel.

ACHTUNG: Die Definition der Höhe ist in der Literatur nicht eindeutig! Stets die gewählte Definition überprüfen. Denn alternativ: Die Höhe eines Baums kann auch die Knotenanzahl des längsten Pfads von der Wurzel sein.

Für einen Binärbaum t der Höhe h gilt:

- i. t hat maximal $2^{h+1} 1$ Knoten.
- *ii.* t hat mindestens h + 1 Knoten
- *iii.* t hat maximal $2^h 1$ innere Knoten.
- iv. t hat maximal 2^h Blätter.



Beweis: (i) per Induktion:

- Ein vollständiger Baum der Höhe h = 0 besteht nur aus der Wurzel und hat $2^{h+1} 1 = 1$ Knoten.
- Angenommen, jeder Binärbaum bis Höhe n hat $2^{n+1} 1$ Knoten.
- Vollst. Baum der Höhe h = n + 1 hat Wurzel (1 Knoten) und zwei vollständige Teilbäume (jeweils $2^{n+1} 1$ Knoten)
 - Insgesamt: $1 + 2 * (2^{n+1} 1) = 2^{n+2} 1$ Knoten.

Für einen Binärbaum t der Höhe h gilt:

- i. t hat maximal $2^{h+1} 1$ Knoten.
- *ii.* t hat mindestens h + 1 Knoten
- iii. t hat maximal $2^h 1$ innere Knoten.
- *iv.* t hat maximal 2^h Blätter.

Beweis: (ii)

Trivial. Betrachte Folge von Knoten mit genau einem Nachfolger.

Für einen Binärbaum t der Höhe h gilt:

- i. t hat maximal $2^{h+1} 1$ Knoten.
- *ii.* t hat mindestens h + 1 Knoten
- *iii.* t hat maximal $2^h 1$ innere Knoten.
- iv. t hat maximal 2^h Blätter.

Beweis: (iii)

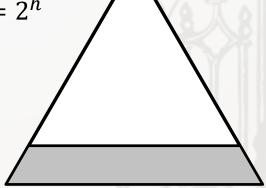
Die Menge der inneren Knoten entspricht dem Teilbaum, wenn man die Blätter abschneidet. Die Behauptung folgt dann mit (i).

Für einen Binärbaum t der Höhe h gilt:

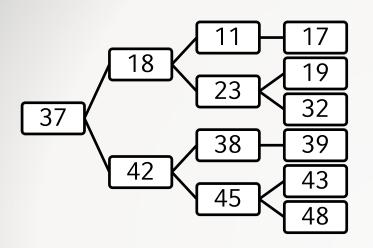
- i. t hat maximal $2^{h+1} 1$ Knoten.
- *ii.* t hat mindestens h + 1 Knoten
- iii. t hat maximal $2^h 1$ innere Knoten.
- iv. t hat maximal 2^h Blätter.

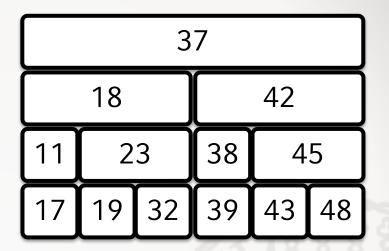
Beweis: (iv)

$$(2^{h+1}-1)-(2^h-1)=2*2^h-2^h=2^h$$



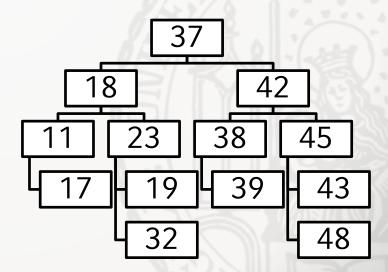
Alternative Baumdarstellungen





37(18(11(17), 23(19,32)), 42(38(39), 45(43,48)))

37	18	11	17
O 1		23	19
		23	32
	42	38	39
		45	43
		45	48



Arrayeinbettung

• Wir wissen: Ein Binärbaum der Höhe h hat $n \le 2^{h+1} - 1$ Knoten.

 Ein Array der Größe n kann daher einen Binärbaum speichern

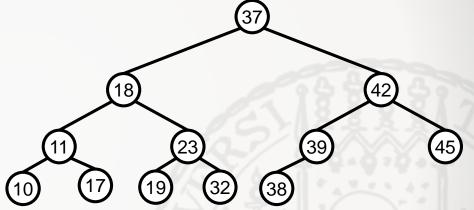
> Ebenen von der Wurzel an in das Array eintragen

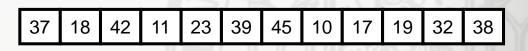
 Leere Positionen im Array freilassen



$$-2i+1, 2i+2$$

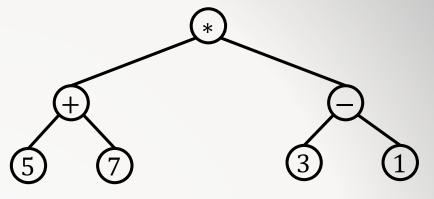
- Vater von Knoten i:
 - $-\lfloor n/2 \rfloor$
- Auf Arraygrenzen achten!





Baumtraversierungen

- Tiefendurchlauf (depth first):
 - Durchlaufe zu jedem Knoten rekursiv die Teilbäume von links nach rechts



- Preorder/Präfix: notiere erst einen Knoten, dann seine Teilbäume
 - Beispiel: * + 5 7 3 1

[polnische Notation]

- Postorder/Postfix: notiere erst Teilbäume eines Knotens, dann ihn selbst
 - Beispiel: 57+31-*
- Inorder/Infix: notiere 1. Teilbaum, dann Knoten selbst, dann restliche Teilbäume
 - Beispiel: 5 + 7 * 3 1

[Mehrdeutigkeit möglich]

- Breitendurchlauf (breadth first):
 - Knoten ebenenweise durchlaufen, von links nach rechts
 - Beispiel: *+-5731
- Alle Durchläufe auf beliebigen Bäumen durchführbar
 - Inorder-Notation nur auf Binärbäumen gebräuchlich

Zusammenfassung Grundlagen

- Probleme und Instanzen
- Algorithmen
 - Definition
 - Darstellungen (Prosa, Pseudocode, Programmcode)
 - Eigenschaften
- Grundlegende Datenstrukturen
 - Arrays
 - Listen
 - Stacks
 - Queues
 - Bäume
 - Eigenschaften
 - Binärbäume
 - Traversierungen