

FAKULTÄT FÜR MATHEMATIK, INFORMATIK UND STATISTIK INSTITUT FÜR INFORMATIK

LEHRSTUHL FÜR DATENBANKSYSTEME UND DATA MINING

Kapitel 3: Sortieren

Einfache Sortierverfahren
Höhere Sortierverfahren
Problemspezifische Komplexitätsschranken



Motivation zum Sortieren

- Anwendungsbeispiele:
 - Priorisierung von Aufgaben zum Zeitmanagement
 - Packaufgaben, schwere/große Gegenstände zuerst einpacken
 - Statistische Übersicht
- Ausgangpunkt: Folge von *Datensätzen* $D_1, D_2, D_3, ..., D_n$
- Jeder Datensatz besitzt eine Schlüsselkomponente D_i . key
- Jeder Datensatz kann außerdem weitere Informationseinheiten enthalten (z.B. Name, Adresse, PLZ, etc.)
- Ziel: Datensätze derart anordnen, dass die Schlüsselwerte sukzessive ansteigen (oder absteigen)
- Bedingung: Schlüssel müssen vergleichbar sein!

Totale Ordnung

Sei M eine nicht leere Menge und $\leq \subseteq M \times M$ eine binäre Relation auf M.

Das Paar (M, \leq) heißt genau dann eine totale (bzw. lineare) Ordnung auf M, wenn folgende Eigenschaften erfüllt sind:

- Reflexivität: $\forall x \in M$: $x \leq x$

- Transitivität: $\forall x, y, z \in M$: $x \le y \land y \le z \Rightarrow x \le z$

- Antisymmetrie: $\forall x, y \in M$: $x \leq y \land y \leq x \Rightarrow x = y$

- Totalität: $\forall x, y \in M$: $x \leq y \lor y \leq x$

Totale Ordnung: Beispiel

- ≤ auf den natürlichen Zahlen bildet eine totale Ordnung.
- Die lexikographische Ordnung \leq_{lex} ist eine totale Ordnung. Sei \leq die totale Ordnung auf den Buchstaben $A \leq B \leq \cdots \leq Z$.
 - Für zwei endliche Wörter $u=a_1\dots a_ku_1\dots u_m$ und $v=a_1\dots a_kv_1\dots v_n$ mit $u,v\in\{A,B,\dots,Z\}^*$ und $u_1\neq v_1$ gilt: $u\leq_{lex}v\Leftrightarrow u_1\leq v_1\vee u_1$ "leer"
 - Beispiel: FRANZ \leq_{lex} FRANZISKA \leq_{lex} PAUL \leq_{lex} PETER
- Die Teilmengenrelation ⊆ auf Potenzmenge von N ist keine totale Ordnung.
 - Beweis: {1} ⊈ {2} und {2} ⊈ {1} verletzen Totalität.

Das Sortierproblem

Gegeben sei eine Folge von Schlüsselwerten

$$a_1, a_2, a_3, \dots, a_n$$

und eine totale Ordnung \leq auf der Schlüsselmenge $\{a_1, ..., a_n\}$.

Die Ausgabe des Sortierproblems ist dann die Folge der Schlüssel

$$a_{\pi(1)}, a_{\pi(2)}, a_{\pi(3)}, \dots, a_{\pi(n)}$$

mit:

- $a_{\pi(i)} \le a_{\pi(i+1)}$ für alle $1 \le i \le n$.
- π ist eine Permutation der Indexmenge $\{1, ..., n\}$.

Das Sortierproblem: Beispiele

Quelle	Schlüsselelement	Ordnung
Telefonbuch	Nachname	Lexikographische Ordnung
Klausurergebnisse	Punktezahl	≤ auf rationalen Zahlen
Lexikon	Stichwort	Lexikographische Ordnung
Studentenverzeichnis	Matrikelnummer	≤ auf N
Entfernungstabelle	Distanz	≤ auf ℝ
Fahrplan	Abfahrtszeit	"früher als"

Vergleichskriterien für Sortieralgorithmen

Sortieralgorithmen können nach verschiedenen Kriterien klassifiziert werden:

- Berechnungsaufwand
 - $O(n^2)$, $O(n \log n)$, O(n)
- Worst Case vs. Average Case
 - Ausnutzen von Vorsortierungen
- Speicherbedarf
 - In-place / in situ
 - Kopieren
- Stabilität
 - Erhalt der Reihenfolge von gleichwertigen Schlüsseln

Vertauschungen und Vergleiche

- Die Applikation ist wichtiger Auswahlfaktor:
 - Ein Verfahren mit vielen Vertauschungen und wenig Vergleichen ist gut geeignet für teure Vergleichsoperationen.
 - Falls die Umsortierung teuer ist, sollte man ein Verfahren mit wenig Vertauschungen wählen.



Beispiel 1: Sortiere Container nach Gewicht

- Teure Vertauschung (Kran, erst weitere Vertauschungen nötig)
- Günstige Vergleiche (Container-ID, Frachtpapiere)



Beispiel 2: Sortiere Beeren nach Vitamingehalt

- Günstige Vertauschung (Nehmen & Ablegen)
- Teure Vergleiche (Labortests, Zeit- und Kostenintensiv)

Weitere Aufgaben

Viele Aufgaben sind mit dem Sortieren verwandt und können auf das Sortierproblem zurückgeführt werden:

- Bestimmung des Median (der Median ist definiert als das Element an der mittleren Position der sortierten Folge)
- Bestimmung der k kleinsten bzw. größten Elemente

Typen von Sortieralgorithmen

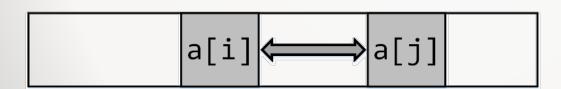
- Einfache
 - BubbleSort
 - SelectionSort
 - InsertionSort
 - **—** ...
- Höhere
 - MergeSort
 - QuickSort
 - HeapSort
 - _ ...
- Spezielle
 - BucketSort
 - **—** ...

Swap

Im Folgenden wird häufiger der Aufruf swap(a, i, j) verwendet, wobei a ein Array ist und i, j int-Werte.

Der Aufruf ersetzt folgende drei Zuweisungen:

```
Object temp = a[i];
a[i] = a[j];
a[j] = temp;
```



BubbleSort

- Idee:
 - Vergleiche Paare von benachbarten Schlüsseln
 - Tausche, falls linker Schlüssel größer ist als rechter
- Durch das repetitive Swapping verhalten sich Elemente wie aufsteigende Luftblasen im Wasser

```
public void bubblesort(int[] a){
  for(int i = 0; i < n; i++) {
    for(int j = 0; j < n-i-1; j++){
      if(a[j] > a[j+1])
        swap(a,j,j+1);
    }
}
```

3 7 8 6 4 2

```
for(int i = 0; i < n; i++) {
   for(int j = 0; j < n-i-1; j++){
     if(a[j] > a[j+1])
        swap(a,j,j+1);
   }
}
```

i	0
j	0



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 0

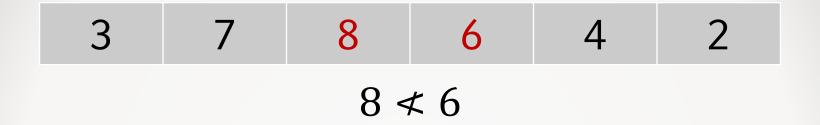
j
0
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++){
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 0

j 1
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
    swap(a,j,j+1);
  }
}

j
2
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
    swap(a,j,j+1);
  }
}

j
2
```



```
for(int i = 0; i < n; i++) {
   for(int j = 0; j < n-i-1; j++){
     if(a[j] > a[j+1])
        swap(a,j,j+1);
   }
}
```

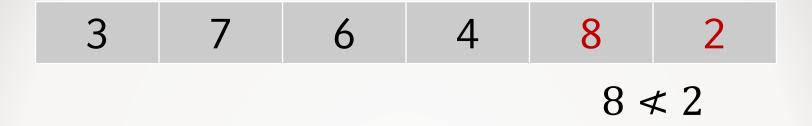
i	0
j	3

```
3 7 6 4 8 2 Swap
```

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 0

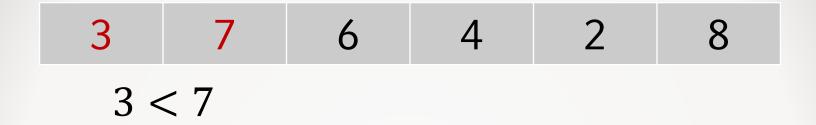
j 3
```



```
3 7 6 4 2 8 Swap
```

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++){
    if(a[j] > a[j+1])
    swap(a,j,j+1);
  }
}

j
4
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 1

for(int i = 0; i < n; i++) {
  if(a[j] > a[j+1])
      swap(a,j,j+1);
      j
```







```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 1

2
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 1

2
```



```
3 6 4 2 7 8

Swap
```

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

in 1

1

3
```



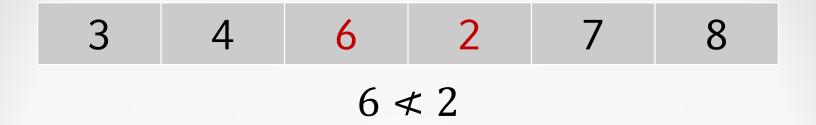
```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 2

j
0
```







```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 2

2

j 2
```

```
3 4 2 6 7 8
Swap
```

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++){
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 2

j 2
```



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

j
0
```





BubbleSort: Beispiel



```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 4

j

j

j

j
```

BubbleSort: Beispiel

2 3 4 6 7 8 Swap

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++) {
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 4

j

j

j

j
```

BubbleSort: Beispiel

2 3 4 6 7 8

Sortiert!

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++){
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}

i 4

j

j

j

j
```

BubbleSort: Komplexitätsanalyse Vergleiche

```
for(int i = 0; i < n; i++) {
   for(int j = 0; j < n-i-1; j++){
     if(a[j] > a[j+1])
       swap(a,j,j+1);
   }
}
```

- Anzahl der Vergleiche:
 - Unabhängig von der Vorsortierung der Folge
 ⇒ worst case, average case und best case sind identisch (es werden stets alle Elemente der noch nicht sortierten Teilfolge miteinander verglichen)
 - Im i-ten Schleifendurchlauf werden n-i-1 Elemente betrachtet und n-i-2 Paare verglichen, insgesamt:

$$\sum_{i=1}^{n-1} (n-i-2) = \sum_{i=1}^{n-1} (i-2) = O(n^2)$$

BubbleSort: Komplexitätsanalyse Vertauschungen

```
for(int i = 0; i < n; i++) {
  for(int j = 0; j < n-i-1; j++){
    if(a[j] > a[j+1])
      swap(a,j,j+1);
  }
}
```

- Anzahl der Vertauschungen:
 - Best Case: 0 Swaps (Vorsortierung)
 - Worst Case: $\frac{1}{2}(n^2 n)$ Swaps (Invertierte Reihenfolge)
 - Average Case: $\frac{1}{2}(n^2 n)$ Swaps
 - » Donald E. Knuth: The Art of Computer Programming (1997)

SelectionSort

- Idee:
 - Durchlaufe die Folge von links nach rechts mit einem Zeiger i.
 - Links von i sind die i-kleinsten Elemente sortiert.
 - Finde in der verbleibenden Menge das kleinste Element und tausche es mit i. Dann erhöhe i um eins.
 - Tausche, falls linker Schlüssel größer ist als rechter

```
public void selectionsort(int[] a){
  for(int i = 0; i < n-1; i++) {
    int min = i;
    for(int j = i+1; j < n; j++){
       if(a[j] < a[min])
        min = j;
    }
    swap(a,i,min);
  }
}</pre>
```

3 7 8 6 4 2

```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	1
min	0



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	1
min	0



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	2
min	0
00/ 11 11	



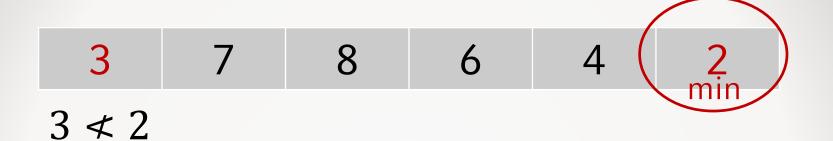
```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	3
min	0



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	4
min	0
1001	



```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>

int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
    swap(a,i,min);
}
</pre>
```



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	0
j	5
min	5



```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>
int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}
```



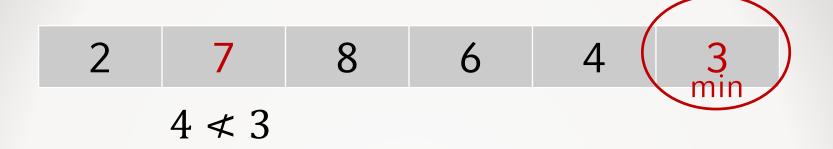
```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	1
j	3
min	3



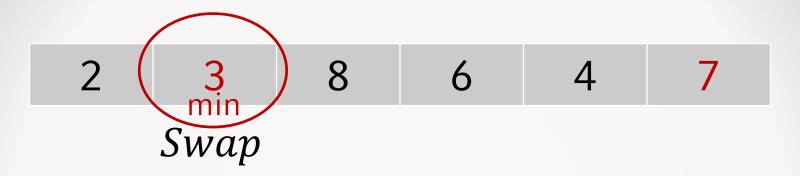
```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	1
j	4
min	4



```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>

int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}
</pre>
```



```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>

i 1

j

for(int j = i+1; j < n; j++) {
  if(a[j] < a[min])
        min = j;
}

swap(a,i,min);
}
</pre>
```



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

3
3



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	2
j	4
min	4
00/	



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	2
j	5
min	4
1 1 1 1 9 0 1	



```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>

i 2

j 5

min 4
```



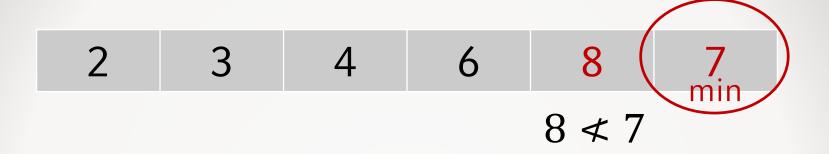
```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	3
j	4
min	3
100	



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	3
j	5
min	3



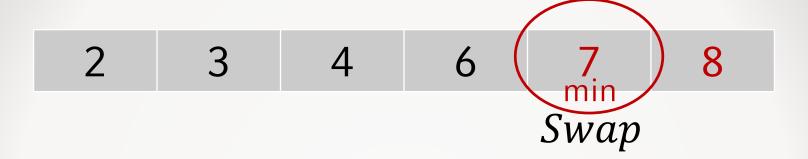
```
for(int i = 0; i < n-1; i++) {
  int min = i;
  for(int j = i+1; j < n; j++) {
    if(a[j] < a[min])
        min = j;
  }
  swap(a,i,min);
}</pre>

i 4

j 5

min 5

min 5
```



```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	4
j	5
min	5
001	

2 3 4 6 7 8

Sortiert!

```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

i	4
j	5
min	5

SelectionSort: Komplexitätsanalyse Vergleiche

```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

- Anzahl der Vergleiche:
 - In jedem der n Durchläufe n-i Vergleiche

$$\Rightarrow \frac{n(n-1)}{2} \in O(n^2)$$

- Durch weitere if-Abfrage (min == i) lässt sich Anzahl der swaps im Austausch gegen n zusätzliche Vergleiche verringern

SelectionSort: Komplexitätsanalyse Vertauschungen

```
for(int i = 0; i < n-1; i++) {
   int min = i;
   for(int j = i+1; j < n; j++){
     if(a[j] < a[min])
       min = j;
   }
   swap(a,i,min);
}</pre>
```

- Anzahl der Vertauschungen:
 - Best Case: n-1 Swaps (0 mit zusätzlicher Abfrage)
 - Worst Case: n 1 Swaps
 - Average Case: n-1 Swaps
- Anzahl Swaps wachsen linear.
 Daher ist SelectionSort besonders für Folgen großer Objekte geeignet, deren Vertauschungen teurer sind.

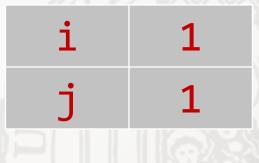
InsertionSort

- Idee:
 - Halte die linke Teilfolge sortiert.
 - Füge nächstes Objekt hinzu, indem es an die korrekte Position eingefügt wird.
 - Wiederhole dies, bis Teilfolge aus der gesamten Liste besteht.

```
public void insertionsort(int[] a){
  for(int i = 1; i < n; i++) {
    int key = a[i];
    int j = i;
    while(j > 0 && a[j-1] > key){
       a[j] = a[j-1];
       j--;
    }
    a[j] = key;
}
```

3 7 8 6 4 2

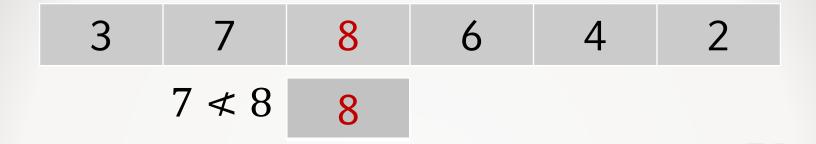
```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



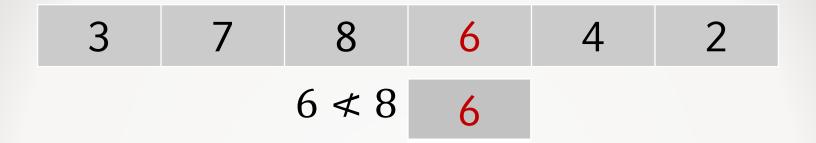
```
    3
    7
    8
    6
    4
    2

    3 < 7</td>
    7
```

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

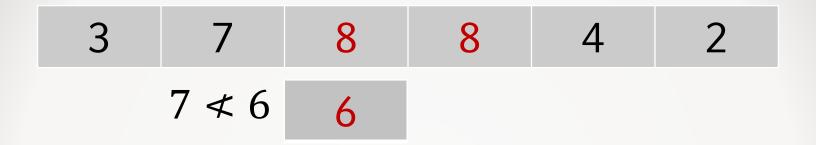


```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

i	3
j	3



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



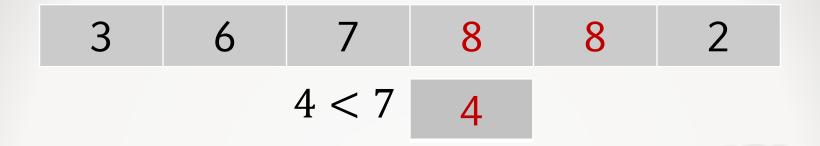
```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

```
3 6 7 8 4 2
insert
```

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

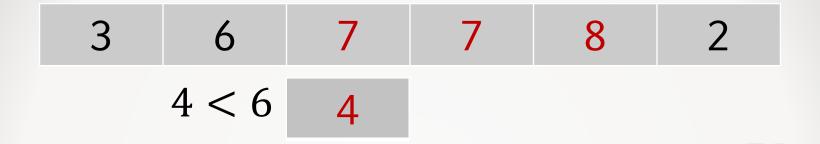


```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



```
for(int i = 1; i < n; i++) {
   int key = a[i];
   int j = i;
   while(j > 0 && a[j-1] > key){
      a[j] = a[j-1];
      j--;
   }
   a[j] = key;
}
```

i	4
j	3



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

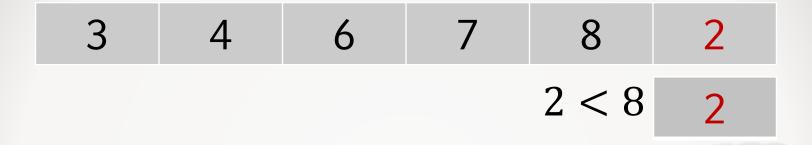
```
    3
    6
    6
    7
    8
    2

    4 ≮ 3
    4
```

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

```
3 4 6 7 8 2
insert
```

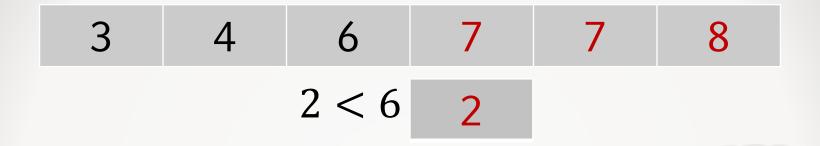
```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

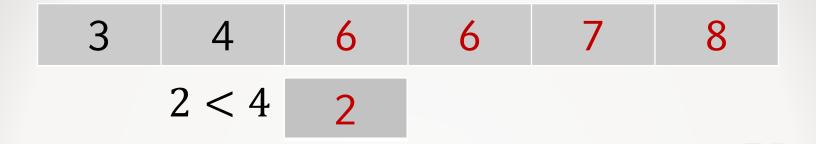


```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

i	5
j	3



```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

```
    3
    4
    4
    6
    7
    8

    2 < 3</td>
    2
```

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

```
3 \quad 3 \quad 4 \quad 6 \quad 7 \quad 8
j = 0! \quad 2
```

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

i 5 j 0

2 3 4 6 7 8

insert

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

i	5
j	0

2 3 4 6 7 8

Sortiert!

```
for(int i = 1; i < n; i++) {
  int key = a[i];
  int j = i;
  while(j > 0 && a[j-1] > key){
    a[j] = a[j-1];
    j--;
  }
  a[j] = key;
}
```

InsertionSort: Sentinel-Variante

Erweitere das Eingabearray vorne um eine Position



Der Code kann nun auf eine Abfrage verzichten:

```
for(int i = 1; i < n; i++) {
   int key = a[i];
   int j = i;
   while(<del>j > 0 &&</del> a[j-1] > key){
      a[j] = a[j-1];
      j--;
   }
   a[j] = key;
}
```

InsertionSort: Komplexitätsanalyse Vergleiche

```
for(int i = 1; i < n; i++) {
   int key = a[i];
   int j = i;
   while(j > 0 && a[j-1] > key){
      a[j] = a[j-1];
      j--;
   }
   a[j] = key;
}
```

- Anzahl der Vergleiche:
 - Abhängig von Vorsortierung
 - Im Best Case O(n) Vergleiche bei sortierter Folge
 - Average Case und Worst Case: $O(n^2)$

InsertionSort: Komplexitätsanalyse Verschiebeoperationen

```
for(int i = 1; i < n; i++) {
   int key = a[i];
   int j = i;
   while(j > 0 && a[j-1] > key){
      a[j] = a[j-1];
      j--;
   }
   a[j] = key;
}
```

- Im besten Fall ist die Folge sortiert und man benötigt keine Verschiebung
- Im schlimmsten Fall ist die Folge absteigend sortiert und das j-te Element wird mit j-1 Operationen an den jeweiligen Anfang geschoben: $\frac{n(n-1)}{2} \in O(n^2)$
- Man kann zeigen, dass im Average Case $\frac{n(n-1)}{4} \in O(n^2)$ Operationen nötig sind.

Fazit: Einfache Sortieralgorithmen

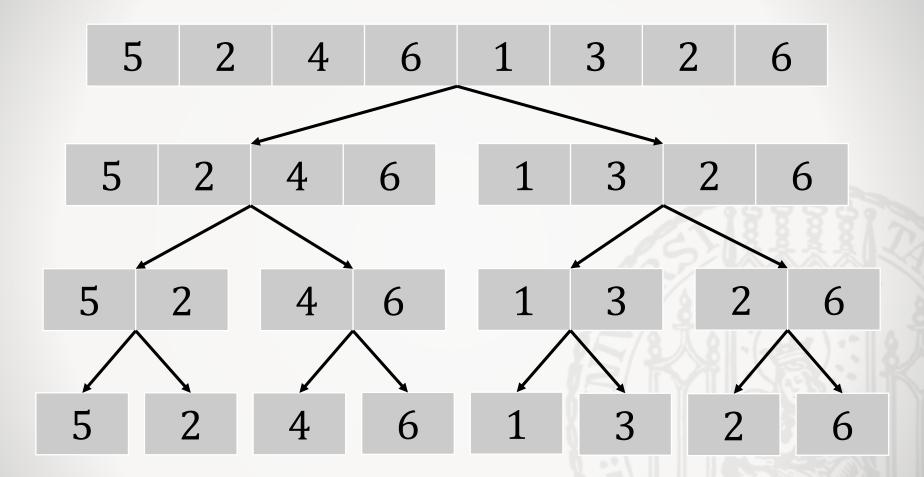
- BubbleSort:
 - Einfache Implementierung.
 - Führt auch im Best Case / Average Case viele Vergleiche aus.
- SelectionSort:
 - Benötigt durchschnittlich weniger Vertauschungen
 - Besser geeignet für teure Vertauschungen und günstige Vergleiche
- InsertionSort:
 - Mehr Vertauschungen, dafür weniger Vergleiche
 - Eignet sich gut, falls die Folge während der Ausführung erweitert wird (Datenstrom)
- Bislang benötigen alle Algorithmen $O(n^2)$ Vergleiche oder Bewegungen.

Geht es auch besser?

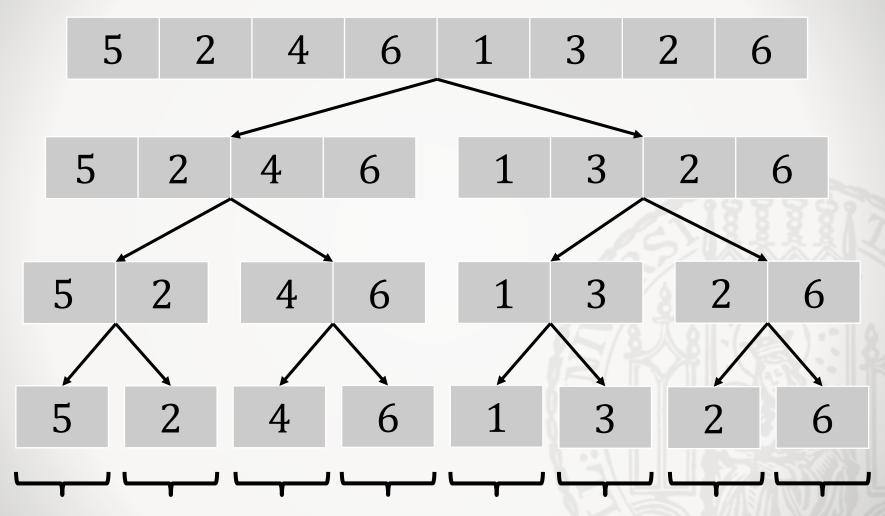
MergeSort

- Idee:
 - Zerlege die Eingabefolge in zwei gleichlange Folgen. Diese lassen sich dann unabhängig vorsortieren.
 - Anschließend werden beide Teilfolgen zusammengefügt.
 - Rekursiv können diese Schritte auch auf die Teillisten angewendet werden.
- Diese Strategie ist bekannt als Divide-and-Conquer
 - **Divide**: Zerlegen der Folge $F = \left(a[1], ..., a\left[\left\lceil\frac{n}{2}\right\rceil\right]\right) \circ \left(a\left[\left\lceil\frac{n}{2}\right\rceil + 1\right], ..., a[n]\right) = F_L \circ F_R$
 - Conquer: Sortiere F_L und F_R mittels MergeSort, falls $|F_L| > 1$ bzw. falls $|F_R| > 1$.
 - Merge: Verschmelze sortierte Teilfolgen F_L und F_R zu sortierter Gesamtfolge

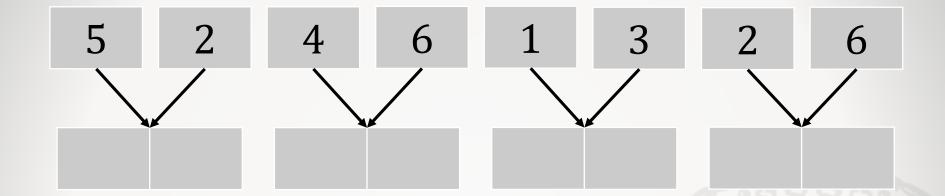
MergeSort: Divide-Schritt

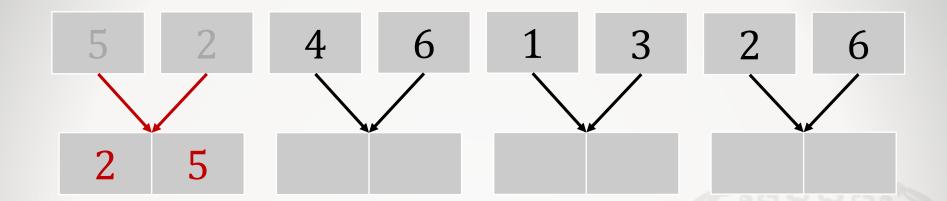


MergeSort: Conquer-Schritt



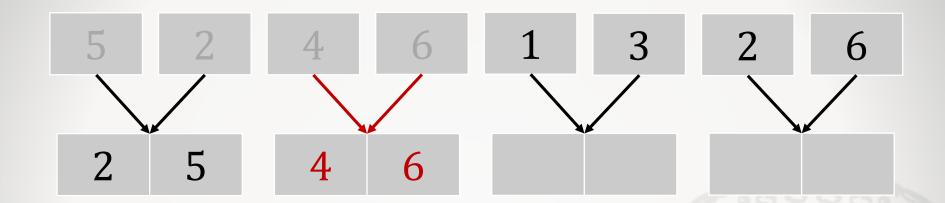
Atomare (einelementige) Folgen sind immer sortiert





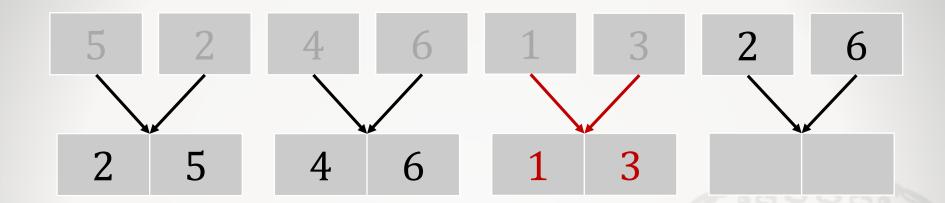
Vergleiche:

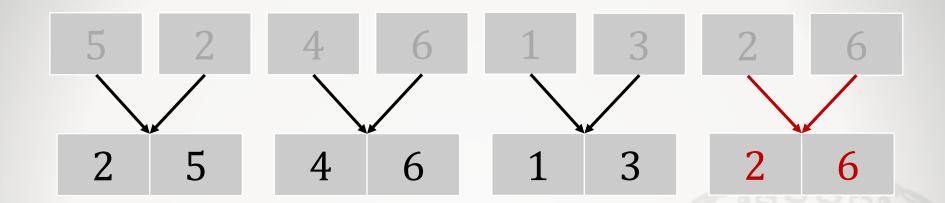
5 < 2?

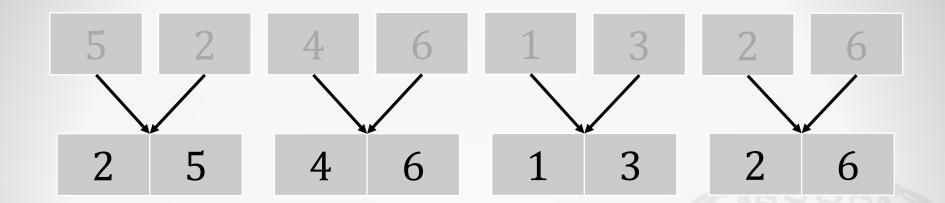


Vergleiche:

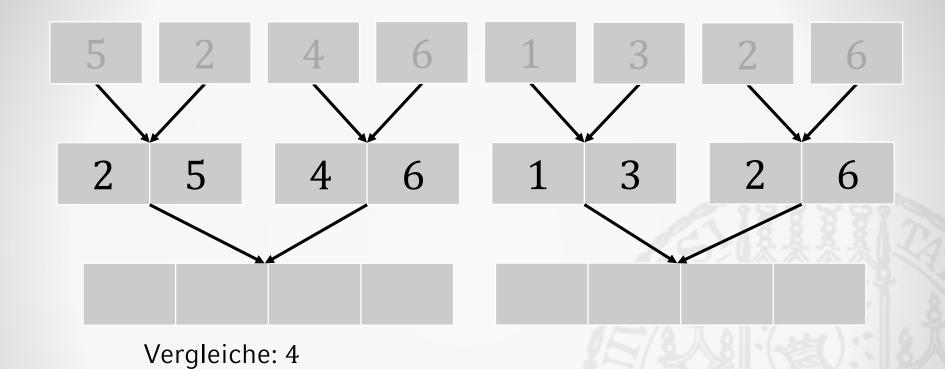
5 < 2? 4 < 6?

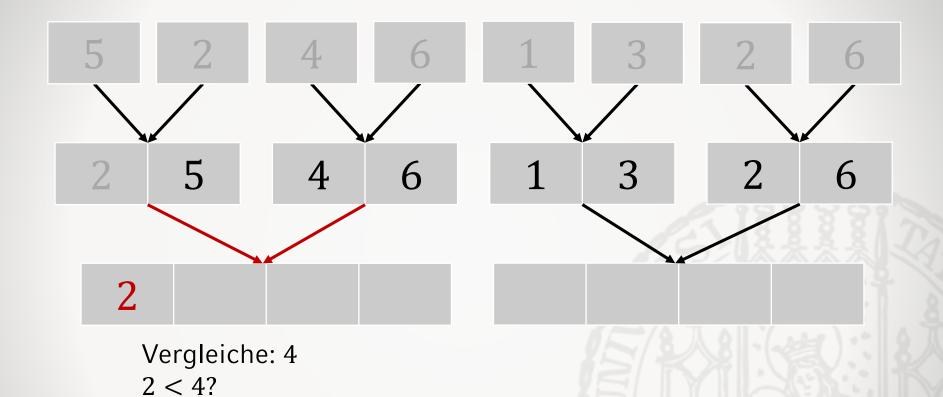


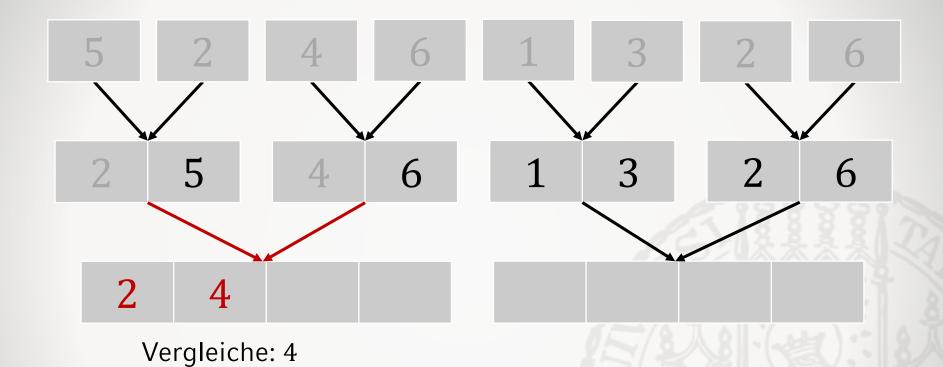




$$5 < 2? \ 4 < 6? \ 1 < 3? \ 2 < 6? \Rightarrow 4 \ Vergleiche$$

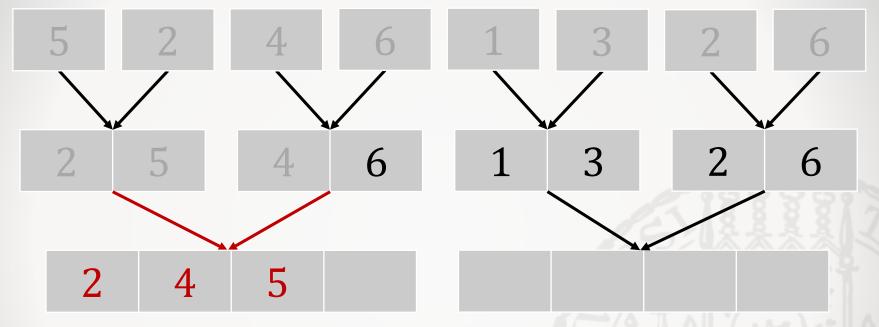






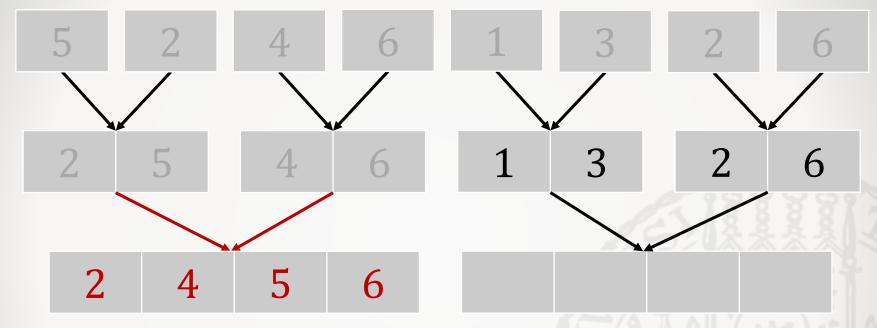
Algorithmen und Datenstrukturen - Kapitel 3

2 < 4? 5 < 4?



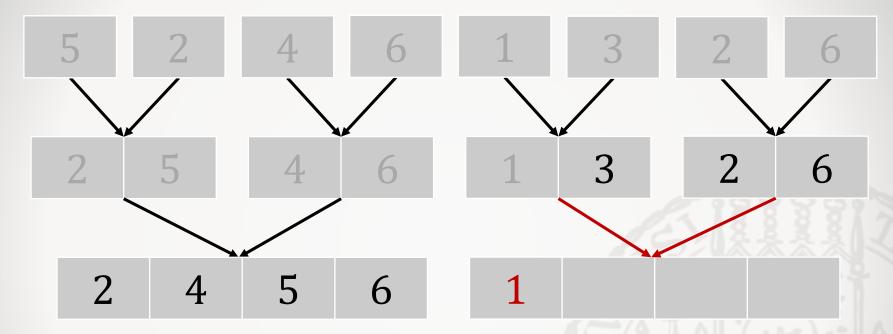
Vergleiche: 4

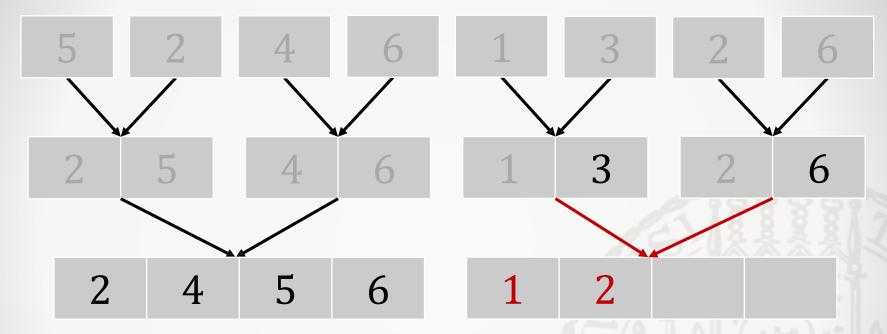
2 < 4? 5 < 4? 5 < 6?

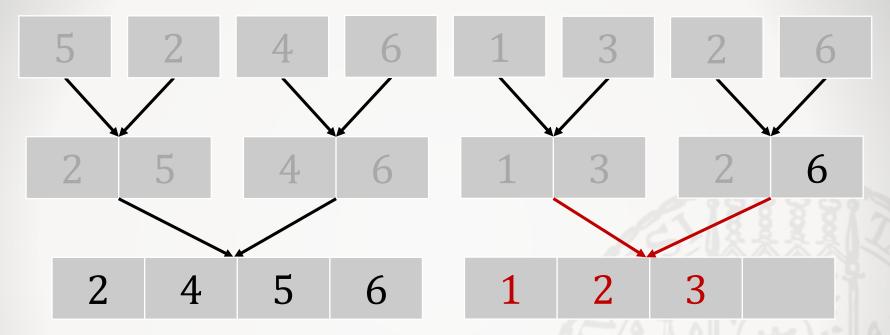


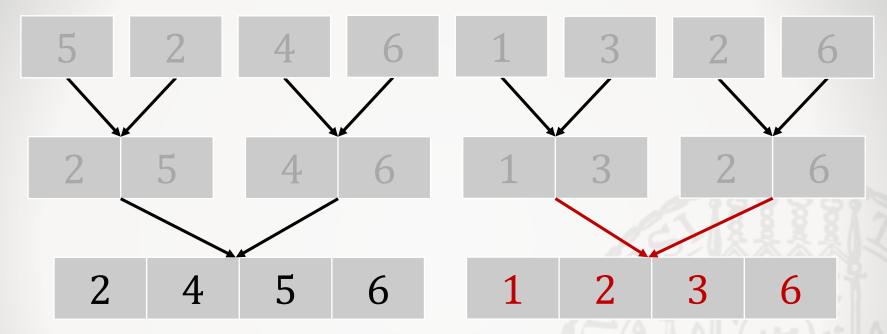
Vergleiche: 4

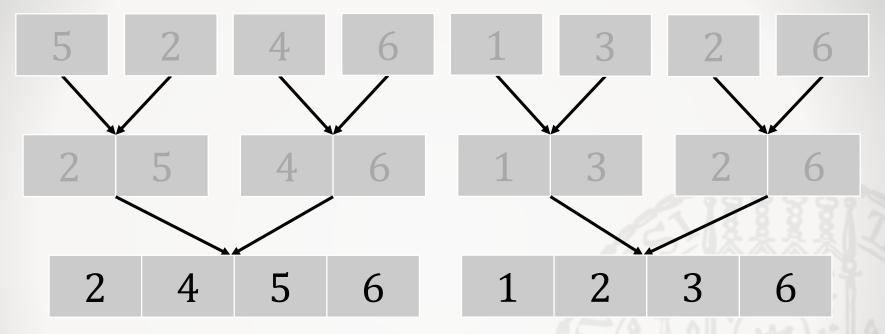
2 < 4? 5 < 4? 5 < 6?





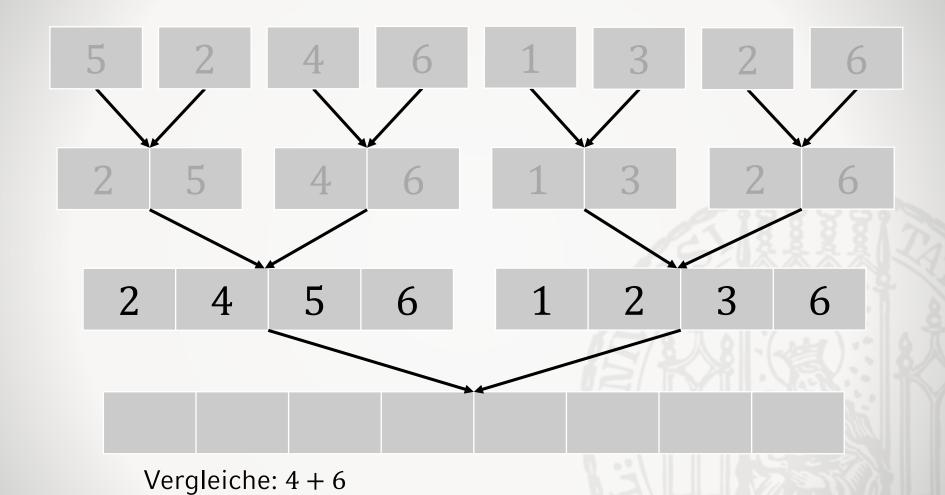


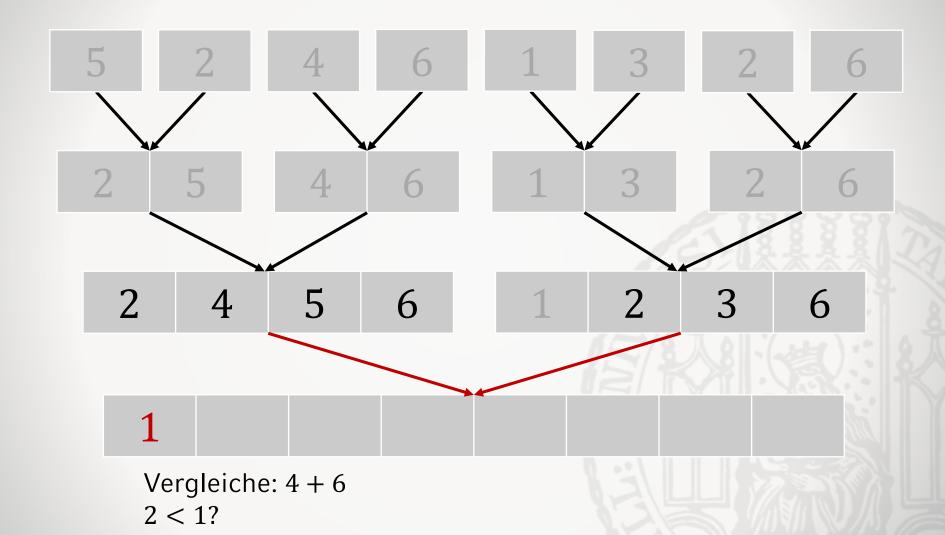


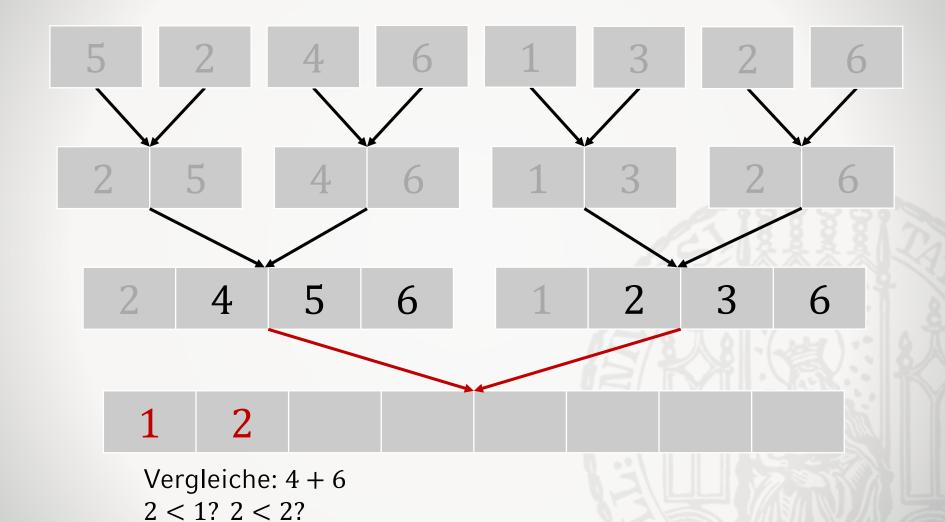


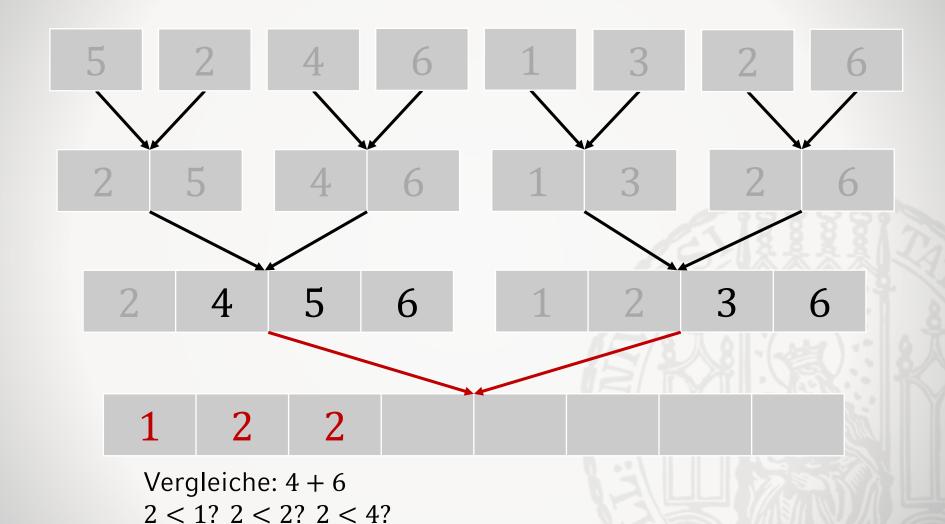
Vergleiche: 4 + 6

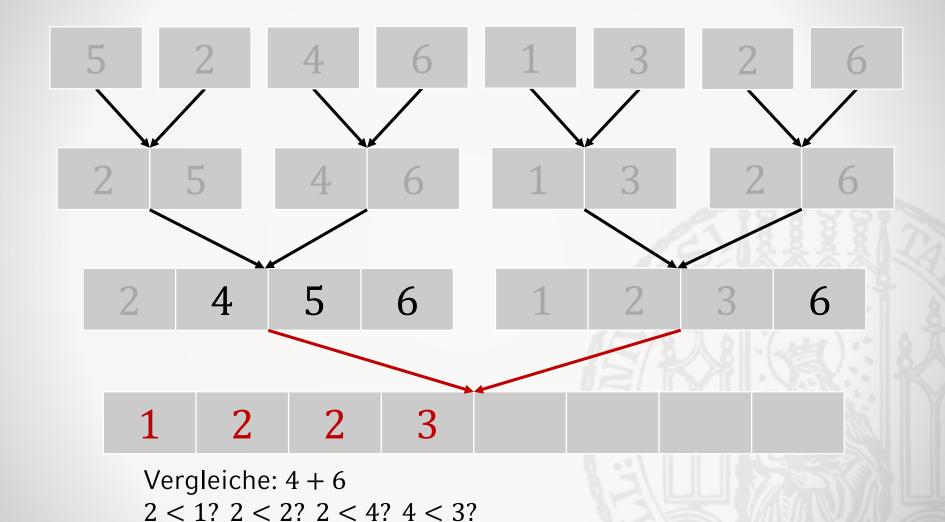
2 < 4? 5 < 4? 5 < 6? 1 < 2? 3 < 2? $3 < 6? \Rightarrow$ 6 Vergleiche

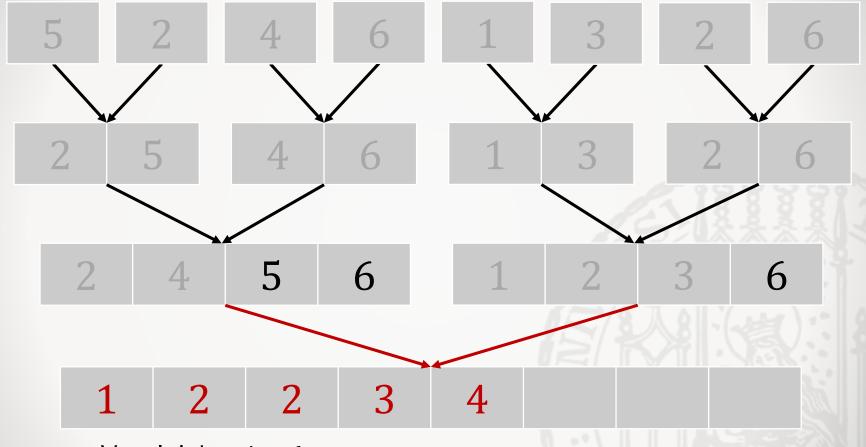






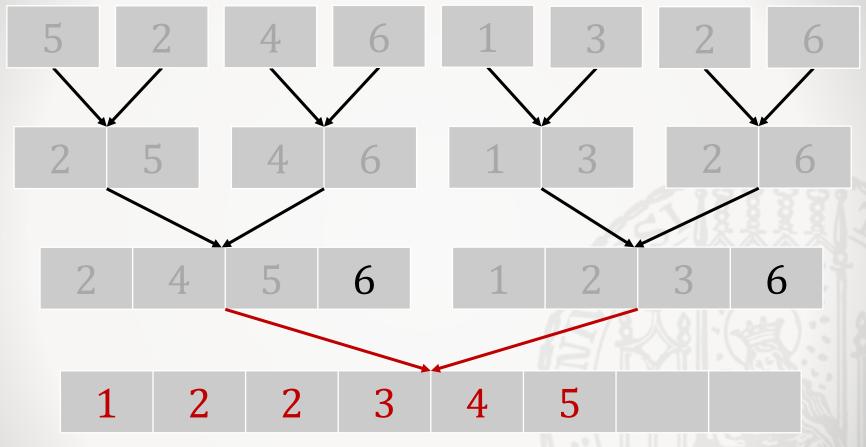






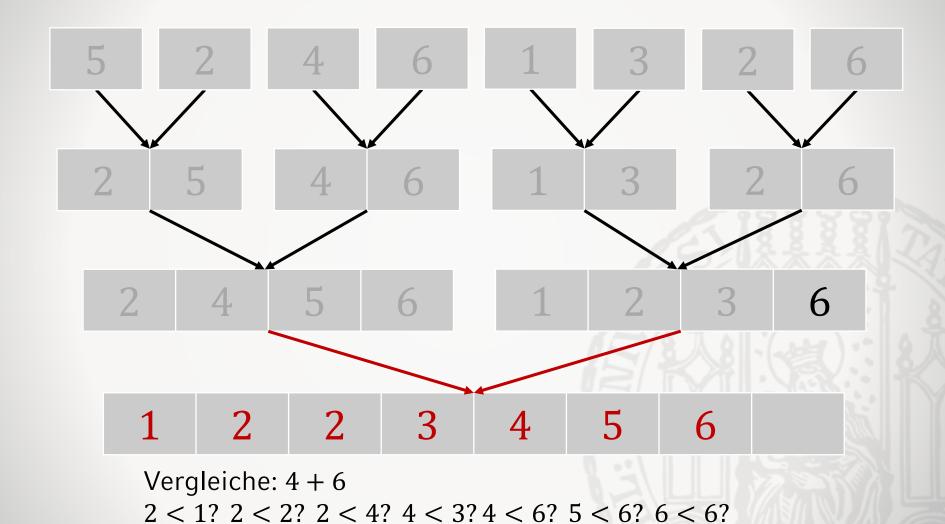
Vergleiche: 4 + 6

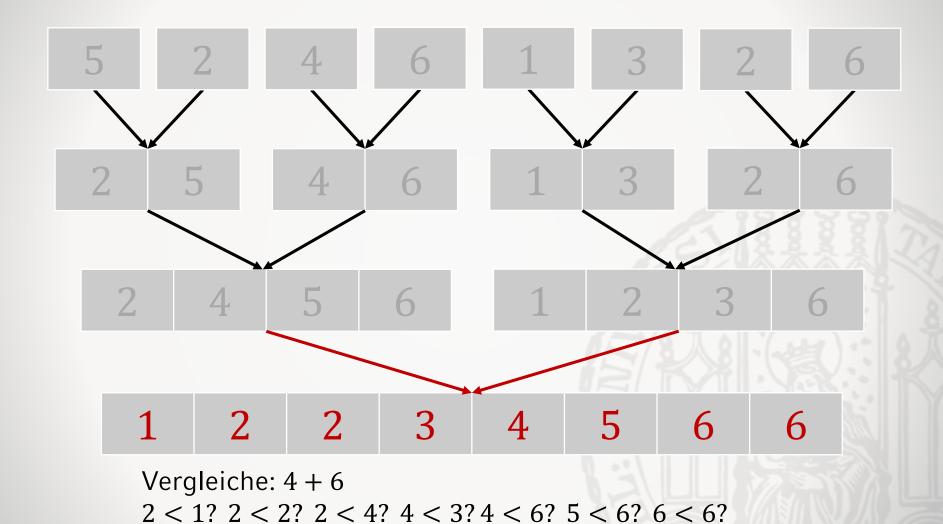
2 < 1? 2 < 2? 2 < 4? 4 < 3? 4 < 6?

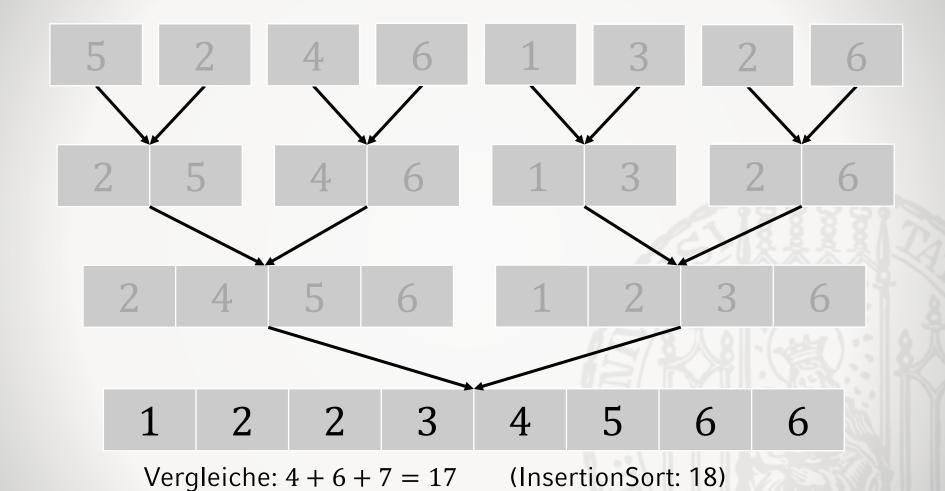


Vergleiche: 4 + 6

2 < 1? 2 < 2? 2 < 4? 4 < 3? 4 < 6? 5 < 6?







2 < 1? 2 < 2? 2 < 4? 4 < 3? 4 < 6? 5 < 6? 6 < 6? ⇒ 7 Vergleiche

Algorithmen und Datenstrukturen - Kapitel 3

MergeSort: Implementierung mit Listen

Implementierung meist mit temporärem Hilfsarray oder mit Listen

```
void mergesort(int[] a) {
                                            void merge(int[] a, int l, int q, int r) {
  mergesort(a, 0, a.length);
                                              int[] arr = new int[a.length];
                                              int i, j;
                                              for (i = 1; i <= q; i++)
                                                arr[i] = a[i];
void mergesort(int[] a, int l, int r) {
                                              for (j = q + 1; j <= r; j++)
  if (1 < r) {
                                                arr[r + q + 1 - j] = a[j];
    int q = (1 + r) / 2;
    mergesort(a, 1, q);
                                              i = 1;
    mergesort(a, q + 1, r);
                                              i = r;
    merge(a, 1, q, r);
                                              for (int k = 1; k <= r; k++) {
                                                if (arr[i] <= arr[j]) {</pre>
                                                  a[k] = arr[i];
                                                  i++;
                                                } else {
                                                  a[k] = arr[j];
                                                  j--;
```

MergeSort: Implementierung mit Hilfsarray

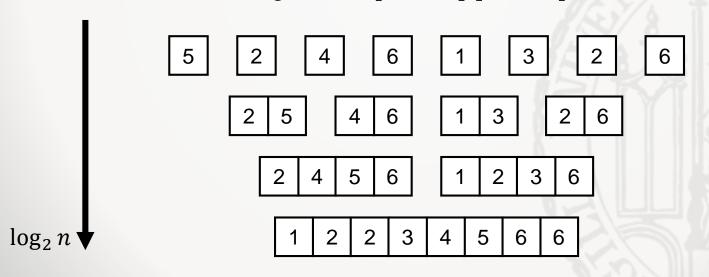
- Implementierung in-place möglich, aber nicht trivial
- Stattdessen oft mit temporären Hilfsarray oder meist mit Listen

```
void mergesort(int[] a) {
                                            void merge(int[] a, int l, int q, int r) {
  mergesort(a, 0, a.length);
                                              _int[] arr = new int[a.length];
                                              int i, j;
                                              for (i = 1; i <= q; i++)
                                                arr[i] = a[i];
void mergesort(int[] a, int l, int r) {
                                              for (j = q + 1; j <= r; j++)
  if (1 < r) {
                                                arr[r + q + 1 - j] = a[j];
    int q = (1 + r) / 2;
    mergesort(a, 1, q);
                                              i = 1;
    mergesort(a, q + 1, r);
                                              j = r;
    merge(a, 1, q, r);
                                              for (int k = 1; k <= r; k++) {
                                                if (arr[i] <= arr[j]) {</pre>
                                                  a[k] = arr[i];
                                                  i++;
                 Doppelter Speicheraufwand
                                                } else {
                 skaliert immer noch linear,
                                                  a[k] = arr[j];
                 da 2n \in O(n)
                                                  j--;
```

MergeSort: Komplexitätsanalyse

Erinnerung: Binärbaum mit n Knoten hat maximal Höhe $h = \log_2 n$.

- Wieviele Vergleiche werden benötigt:
 - In der Divide-Phase wird nichts verglichen
 - In der Merge-Phase werden maximal $\log_2 n$ Teilphasen (Baumebenen im Beispiel) durchgeführt.
 - Die i-te Teilphase besteht maximal aus $\frac{n}{2^{i+1}}$ Mergeoperationen
 - In jeder Mergeoperation kann es zu $2^i 1$ Vergleichen kommen (Bei "Verzahnung", z.B.: [1,3,5,7] [2,4,6,8])



- 1. Teilphase
- 2. Teilphase
- 3. Teilphase

QuickSort

- Idee:
 - Wähle ein Element der Folge p (Pivotelement) aus.
 - Zerlege die Folge in zwei Teilfolgen:
 - Teilfolge 1: Enthält alle Elemente $x \le p$
 - Teilfolge 2: Enthält alle Elemente x > p
 - Sortiere rekursiv auf den Teillisten mit Quicksort.
 - Einelementige Listen sind schon sortiert.
 - Im Gegensatz zu Mergesort:
 - Aufwand liegt im Divide-Schritt.
 - Merge-Schritt ist lediglich Konkatenation.

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

 2
 4
 1
 3
 2
 5
 6
 6

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

 2
 4
 1
 3
 2
 5
 6
 6

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

 2
 4
 1
 3
 2
 5
 6
 6

 1
 2
 2
 4
 3
 5
 6
 6

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

 2
 4
 1
 3
 2
 5
 6
 6

 1
 2
 2
 4
 3
 5
 6
 6

Pivot:
Wir benutzen hier das erste
Listenelement als Pivot!

 5
 2
 4
 6
 1
 3
 2
 6

 2
 4
 1
 3
 2
 5
 6
 6

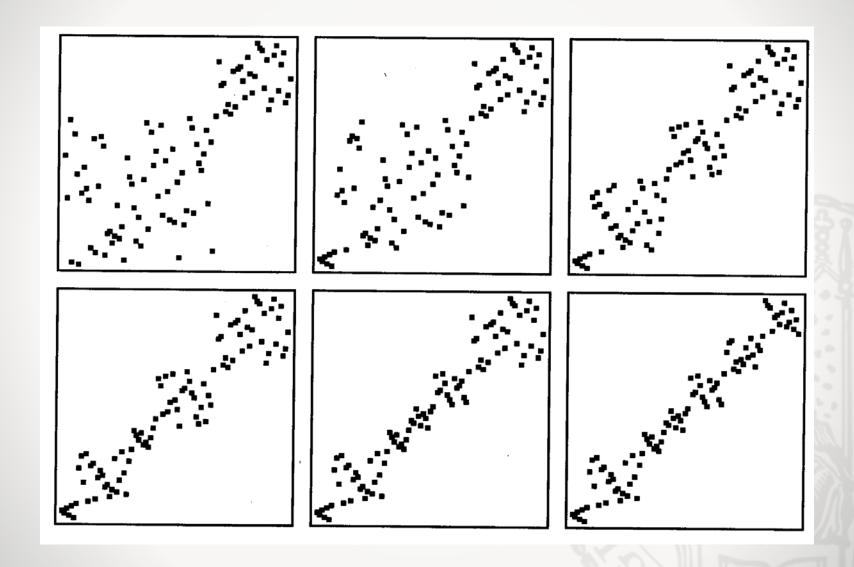
 1
 2
 2
 4
 3
 5
 6
 6

 1
 2
 2
 3
 4
 5
 6
 6

Pivot: Wir benutzen hier das erste Listenelement als Pivot!

6 3 3 3 6

QuickSort: Visualisierung



QuickSort: Implementierung

Wir wählen das mittlere Element als Pivot (sonst vertauschen).

```
void quicksort(int[] a) {
 quicksort(a, 0, a.length - 1);
void quicksort(int[] a, int left, int right) {
 int i = left;
 int j = right;
 int pivot = a[i + (j - i)/2]; \leftarrow Pivot
 while(i <= j) {
   while(a[i] < pivot) i++; Zwei Iteratoren laufen gegenläufig
   while(a[j] > pivot) j--;
                                in Richtung Mitte/Pivot
    if(i <= j) {
      swap(a, i, j);
                        Falls linkes Element kleiner und rechtes
      i++;
                        Element größer als Pivot ist, tausche
      j--;
                        beide Elemente
 if(left < j) quicksort(a, left, j);</pre>
                                            Rekursionen
  if(i < right) quicksort(a, i, right); ←
```

QuickSort: Komplexitätsanalyse Best-Case

- Wir betrachten die Anzahl der Vergleichsoperationen.
- Best-Case: Die Folge zerfällt immer in zwei gleich große Teile.
- Das Pivot wird mit allen übrigen Elementen verglichen.
- Die beiden Teilfolgen enthalten nicht mehr das Pivot.
- Beide Teilfolgen werden ebenfalls sortiert.
- Wenn eine Folge nur noch aus einem Element besteht, werden keine Vergleiche mehr benötigt.

$$T(n) = \begin{cases} 2 \cdot T\left(\frac{n-1}{2}\right) + n - 1 & , n > 1 \\ 0 & , n = 1 \end{cases}$$

Mit Mastertheorem gilt $T(n) \in O(n \log n)$.

QuickSort: Komplexitätsanalyse Worst-Case

- Die Folge zerfällt schlimmstenfalls immer in
 - eine leere Folge
 - und eine Folge der Länge n-1.
- Der Aufrufbaum ist somit ein entarteter Baum (ein linearer Zweig)

$$T(n) = \begin{cases} T(n-1) + n - 1 & , n > 1 \\ 0 & , n = 1 \end{cases}$$

Mit Mastertheorem gilt $T(n) \in O(n^2)$.

 Im schlimmsten Fall ist QuickSort damit genauso langsam wie BubbleSort / SelectionSort / InsertionSort

QuickSort: Komplexitätsanalyse Average-Case (1/2)

- Annahmen:
 - Alle n Schlüssel seien verschieden.
 - Die Wahrscheinlichkeit der Eingabeanordnung sei $\frac{1}{n!}$.
 - Jede der n! Permutationen ist damit gleich wahrscheinlich.
- Bei der Partitionierung entstehen zwei Teilfolgen, die Längen im Interval (0, n-1) annehmen können. Jede Länge ist gleich wahrscheinlich. Der Möglichkeitsraum der Längenpaare ist daher

$$\{(0, n-1), (1, n-2), \dots, (n-2,1), (n-1,0)\}$$

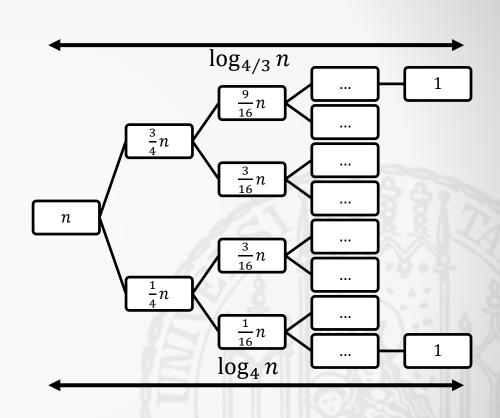
Im Durchschnitt ist daher die Länge der größeren Teilfolge:

$$L_1 = \frac{2}{n} \sum_{i=\frac{n}{2}}^{n-1} i = \frac{3}{4}n - \frac{3}{2}$$

• Wir können die Länge zu $L_1 = \frac{3}{4}n$ abschätzen, da es dadurch nur langsamer wird.

QuickSort: Komplexitätsanalyse Average-Case (2/2)

- $L_1 = \frac{3}{4}n, L_2 = \frac{1}{4}n$
- Der längste Rekursionspfad besteht aus $\log_{4/3} n$ Knoten.
- Jedes Level des Aufrufbaums nutzt O(n) Vergleiche
- Damit ergeben sich
 O(n log n) Vergleiche im
 durchschnittlichen Fall.



QuickSort: Pivotelement

- Pivot (frz.): Dreh-/Angelpunkt
- Die Wahl des Pivots beeinflusst stark die Ausführung und Rekursionstiefe des Algorithmus.
 - Beispiel: Sortiere 7-elem. Liste und nutze 1. Element als Pivot.

4	2	1	3	6	7	5
2	1	3	4	6	7	5
1	2	3	4	5	6	7
1	2	3	4	5	6	7

 Wie Pivot wählen, damit Worst-Case vermieden wird?

1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7

QuickSort: Pivotelement einfache Auswahlstrategien

- "Wähle immer erstes Element" $p = x_1$
 - Einfach zu implementieren
 - (Teilweise) vorsortierte Listen führen zu schlechter Laufzeit
- "Wähle immer letztes Element" $p = x_n$
 - Gleiche Eigenschaften wie "Wähle immer erstes Element"
- "Wähle immer mittleres Element" $p = x_{[n/2]}$
 - Ebenfalls einfach zu implementieren
 - (Teilweise) vorsortierte Listen nicht kritisch
 - Auch hier lassen sich Worst-Case-Szenarien erstellen
 - Sortiere 6421357

6	4	2	1	3	5	7
1	6	4	2	3	5	7
1	2	6	4	3	5	7
1	2	3	6	4	5	7
1	2	3	4	6	5	7
1	2	3	4	5	6	7
1	2	3	4	5	6	7

QuickSort: Pivotelement Randomized

- Bei deterministischer Wahl eines bestimmten Elements lässt sich stets ein Worst-Case finden.
- Lösung 1: Nicht-deterministisches QuickSort
 - Wähle zufälliges Element als Pivot
 - In der Praxis weit verbreitet (einfach und schnell)
 - Wahrscheinlichkeit für Worst-Case sehr unwahrscheinlich
- Wie sieht eine deterministische optimale Strategie aus?
 - Beide Teilfolgen sollten gleich groß sein.
 - Optimales Pivotelement ist damit der Median.

QuickSort: Pivotelement Median

- Naiver Algorithmus *median*
 - Gegeben ist eine Folge $X = x_1 x_2 \dots x_n$
 - Sortiere X
 - Gib Element an Position $\lfloor n/2 \rfloor$ aus
- Aufwand: Worst-Case $O(n \log n)$ bis $O(n^2)$ wegen Sortieren
 - QuickSort hätte dann $O(n \log^2 n)$.
- Geht das besser?
 Können wir das k kleinste Element in linearer Zeit finden?

SELECT - Algorithmus

- Bestimme Median-of-Medians (MoM):
 - Partitioniere die Folge in Subfolgen der Länge $5 \Rightarrow O(n)$.
 - Bestimme in allen 5er-Blöcken den Median $\Rightarrow O(1)$.
 - Bestimme rekursiv den Median $\Rightarrow T(n) \ge T(n/5)$.
- Arrangiere die Folge so, dass alle kleineren Elemente links und alle größeren Elemente rechts vom MoM stehen $\Rightarrow O(n)$.
- Falls der Index des MoM gleich $\lceil n/2 \rceil$ ist, dann haben wir den Median gefunden $\Rightarrow O(1)$.
- Falls der Index des MoM kleiner als $\lfloor n/2 \rfloor$ ist, dann befindet sich der Median im rechten Feld. Wiederhole den Algorithmus dort.
- Falls der Index größer als $\lfloor n/2 \rfloor$ ist, dann befindet sich der Median im linken Feld. Wiederhole den Algorithmus dort $\Rightarrow T(n) = ?$.

SELECT - Algorithmus: Beispiel

- Median von [5, 2, 17, 13, 14, 7, 16, 4, 2, 18, 10, 8, 4, 11]
- 5er Blöcke:
 - [5, 2, 17, 13, 14] [7, 16, 4, 2, 18] [10, 8, 4, 11]
 - Mediane: 13, 7, 8
 - Medians-of-Medians: 7
- Neu anordnen: [5, 2, 4, 2, 4, 7, 8, 17, 13, 14, 16, 18, 10, 11]
- Echter Median müsste an Index [14/2] stehen, daher kann 7 nicht der Median sein (steht bei Index 6).
 - Suche also weiter in rechter Folge:

SELECT - Algorithmus: Beispiel (2)

- Median von [8, 17, 13, 14, 16, 18, 10, 11]
- 5er Blöcke:
 - **–** [8, 17, 13, 14, 16] [18, 10, 11]
 - Mediane: 14, 10
 - Medians-of-Medians: 10
- Neu anordnen: [8, 10, 17, 13, 14, 16, 18, 11]
- In der gesamten Liste:

• Echter Median müsste an Index [14/2] stehen, daher kann 10 nicht der Median sein (steht bei Index 8).

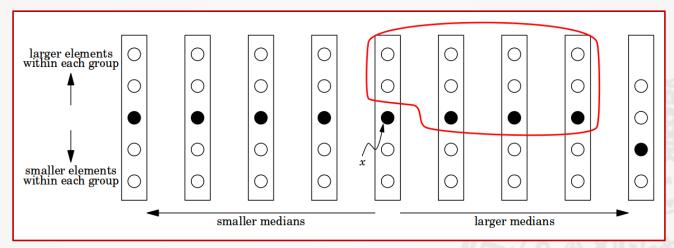
Suche also weiter in linker Folge:

[8]

• [5, 2, 4, 2, 4, 7, 8, 10, 17, 13, 14, 16, 18, 11]
Die 8 ist an der richtigen Stelle und damit das Ergebnis.

SELECT - Algorithmus: Komplexität

 Wieviele Elemente sind beim Divide-Schritt nach der Median-Kandidatbestimmung schlimmstenfalls kleiner (oder größer) als der Kandidat x?



- Von den n/5 Gruppen enthält eine Hälfte mindestens 3 Elemente, die größer oder gleich x sind.
- Die Ausnahmen sind zwei Gruppen:
 - Die Gruppe, die x enthält
 - Die letzte evtl. unvollständige Gruppe

SELECT - Algorithmus: Komplexität (2)

- Daher sind mindestens $3\left(\left[\frac{1}{2}\left[\frac{n}{5}\right]-2\right]\right) \ge \frac{3n}{10}-6$ Elemente größer als x (und analog auch genauso viele Elemente kleiner).
- Im schlimmsten Fall ergibt sich damit für die noch ungeklärte Komplexität des letzten Schritts des Algorithmus:

$$T(n) = n - \left(\frac{3n}{10} - 6\right) = \frac{7n}{10} + 6$$

Insgesamt:

$$T(n) = \begin{cases} O(1), & n < 140 \\ T(\lceil n/5 \rceil) + T(7n/10 + 6) + O(n), & n \ge 140 \end{cases}$$
Proof by Magic

Constant

SELECT - Algorithmus: Komplexität (3)

$$T(n) = \begin{cases} O(1), & n < 140 \\ T(\lceil n/5 \rceil) + T(7n/10 + 6) + O(n), & n \ge 140 \end{cases}$$

- Angenommen, $T(n) \le cn$ für eine sehr große Konstante c und alle n < 140. Eine solche Konstante kann stets gefunden werden.
- Sei a eine passende Konstante, sodass $O(n) \le an$ für alle $n \in \mathbb{N}$.
- Nun kommt der Induktionsschritt für $n \ge 140$:

$$T(n) \le c \left[\frac{n}{5} \right] + c \left(\frac{7n}{10} + 6 \right) + an$$

$$\le \frac{cn}{5} + c + \frac{7cn}{10} + 6c + an = cn + \left(-\frac{1}{10}cn + 7c + an \right)$$

$$-\frac{1}{10}cn + 7c + an \le 0 \Leftrightarrow c \ge 10a \left(\frac{n}{n-70} \right)$$

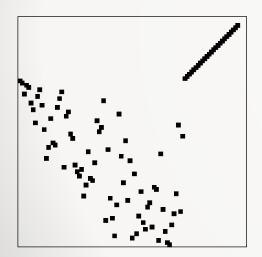
- Da $n \ge 140$, gilt $\frac{n}{n-70} \le 2$ und wir können $c \ge 20a$ wählen.
- Somit gilt $T(n) \le cn$ und SELECT ist in O(n)

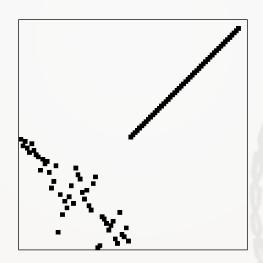
QuickSort: Pivotelement Median

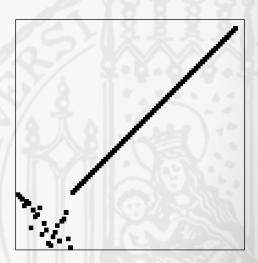
- Nun wissen wir: Es geht mit geeigneter Pivot-Auswahlstrategie schneller als $O(n^2)$.
- Suchen wir immer den Median, verhindern wir stets den Worst-Case. QuickSort ist dann in $O(n \log n)$.
- In der Praxis ist dies jedoch unüblich. Der Worst-Case ist statistisch zu unwahrscheinlich.
- Median-of-three ist die am häufigsten angewendete Strategie.
 - Verwende drei Elemente (z.B. $x_1, x_{\lfloor n/2 \rfloor}, x_n$).
 - Noch besser: Verwende den Median dreier zufälliger Elemente.

HeapSort

- SelectionSort: Wähle n-mal das jeweils nächste Maximum in O(n)
- Falls das immer in $O(\log n)$ ginge, hätten wir ein $O(n \log n)$ Verfahren
- Idee: Stelle das jeweils nächste Maximum in $O(\log n)$ ganz nach vorne.

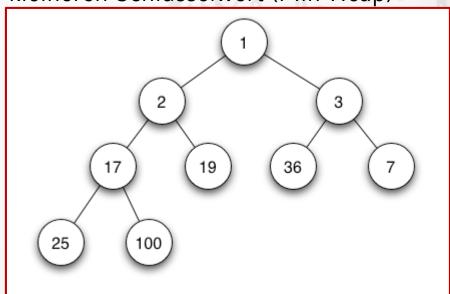






Heap-Struktur

- Ein Heap ist ein Binärbaum, der folgende Eigenschaften erfüllt:
 - Er ist links-vollständig, d.h. jeder Knoten ist entweder ein Blatt oder hat einen linken Kindknoten.
 - Die Knoten enthalten eine Menge von Schlüsselwerten, auf der eine Totalordnung definiert ist.
 - Für jeden Knoten gilt je nach Heap-Variante:
 - Der Vaterknoten hat einen größeren Schlüsselwert (Max-Heap)
 - Der Vaterknoten hat einen kleineren Schlüsselwert (Min-Heap)
- Ein Heap wird daher auch als partiell geordneter Baum bezeichnet.

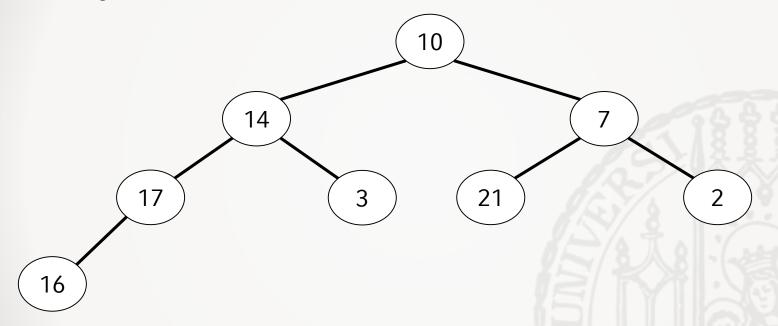


HeapSort: Ablauf

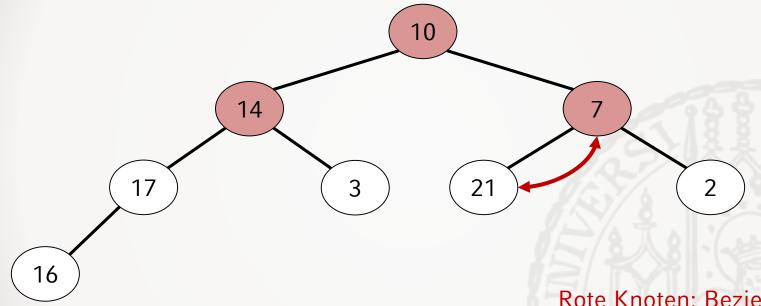
- Füge alle Folgenelemente in einen Binärbaum ein.
- Stelle die Max-Heap-Eigenschaft im Baum her.
 - Von Hinten (Blätter) nach Vorne (Wurzel):
 Prüfe Heap-Eigenschaft; Falls nicht erfüllt, tausche das Vaterelement solange mit dem größeren Kind, bis das Element die Heapeigenschaft erfüllt.
- Für alle Elemente x_i in $(x_0, ..., x_{n-1})$:
 - Tausche Wurzel (größtes Element) mit dem (n i)-ten Element.
 - Stelle für alle Elemente kleiner x_i die Heapeigenschaft wieder her (Versickern)

Gesamter Algorithmus möglich in-place als Arrayeinbettung.

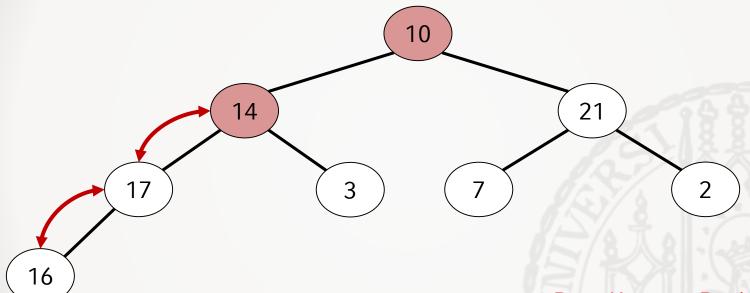
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Einfügen in Binärbaum



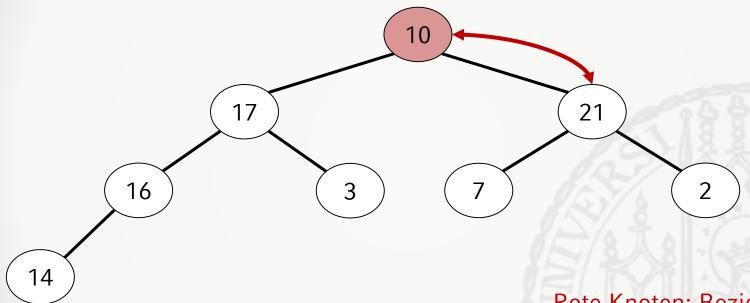
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft herstellen (Heapify)



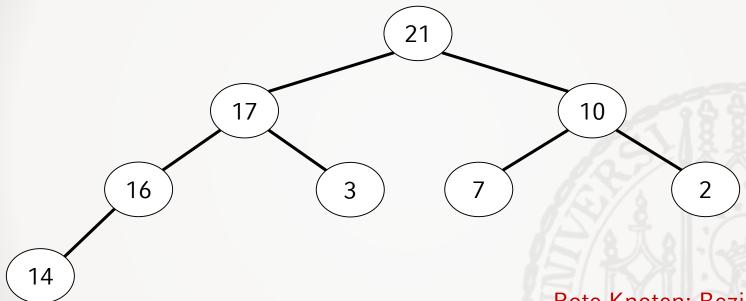
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft herstellen (Heapify)



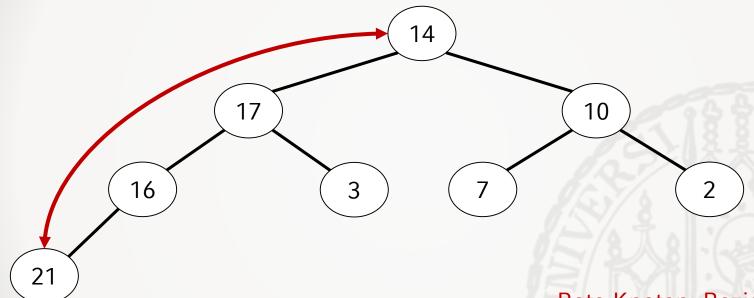
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft herstellen (Heapify)



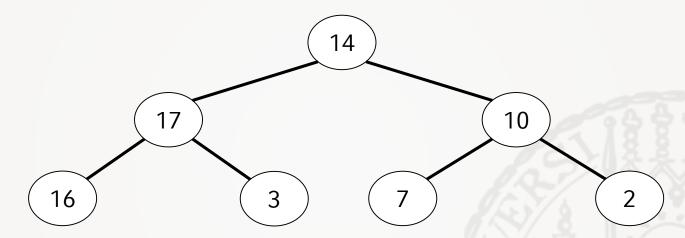
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft hergestellt!



- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element

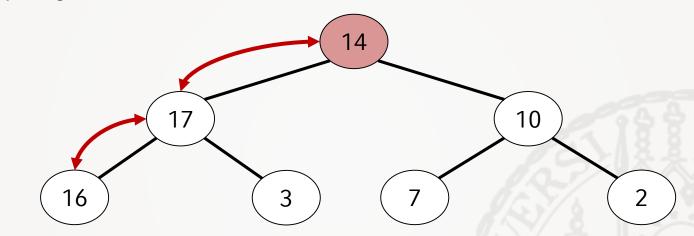


- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



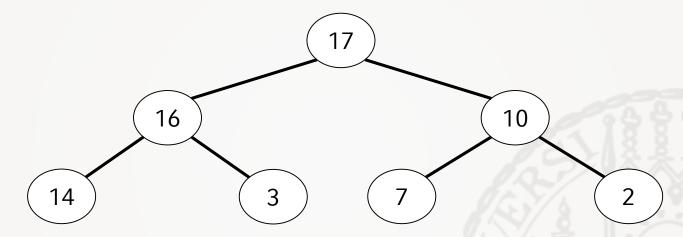
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



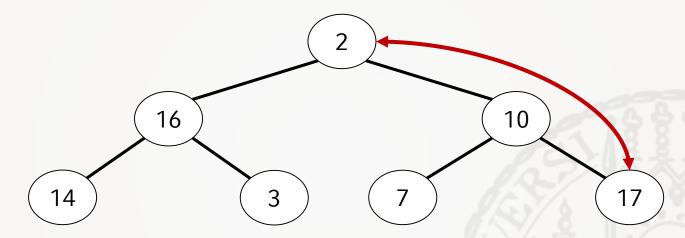
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



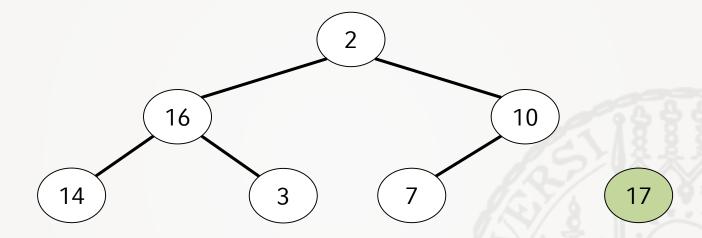
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element



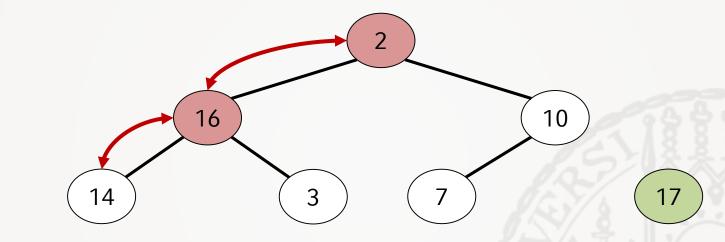
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



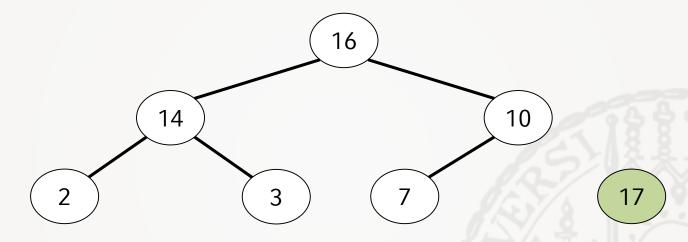
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



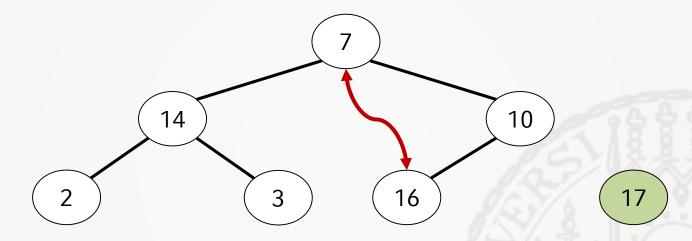
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



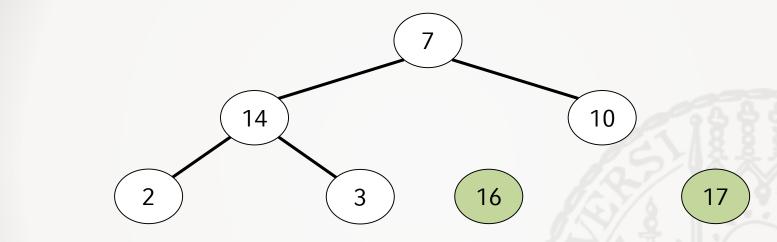
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element



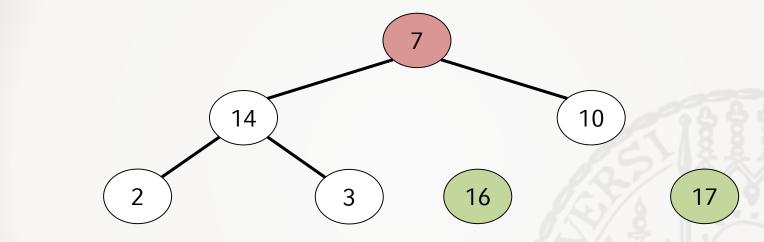


- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



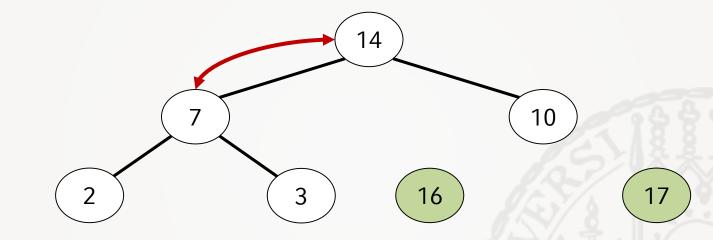
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



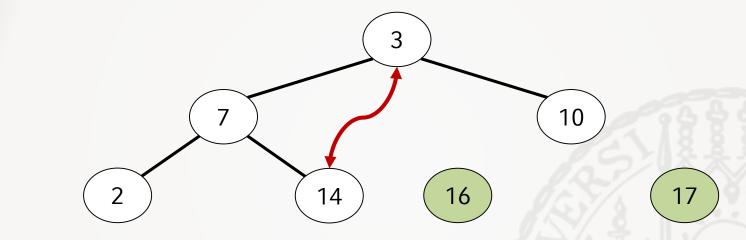
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



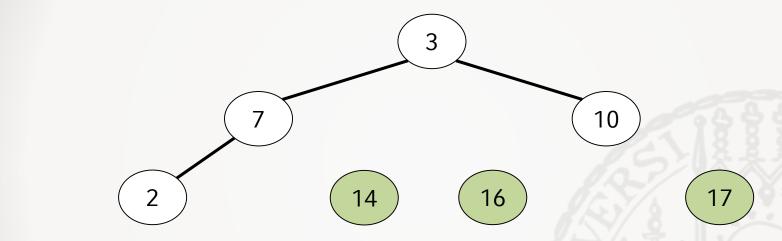
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element



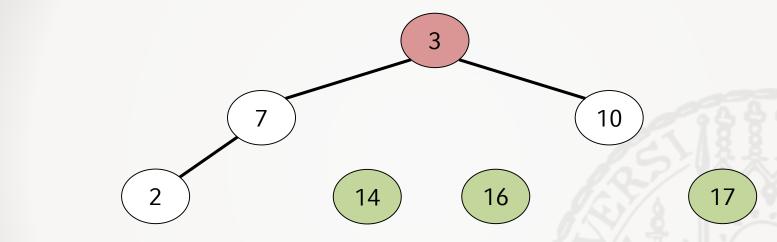
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



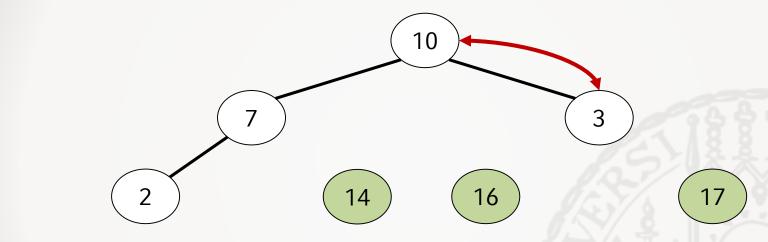


- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



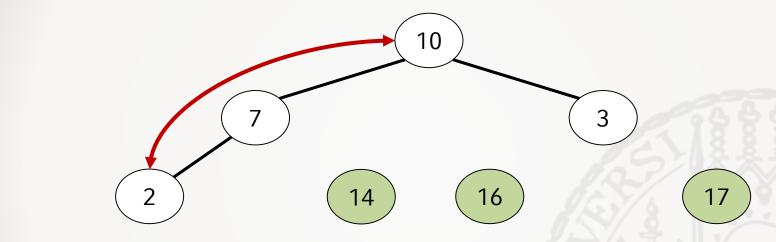
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



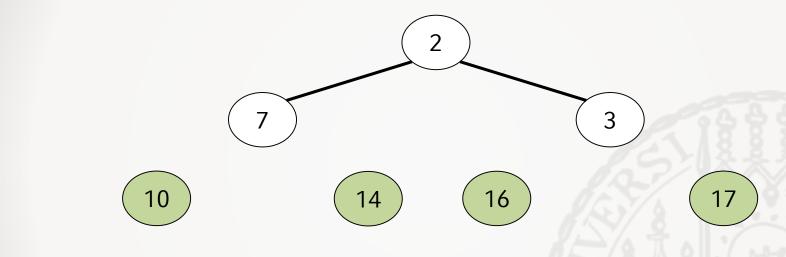
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element



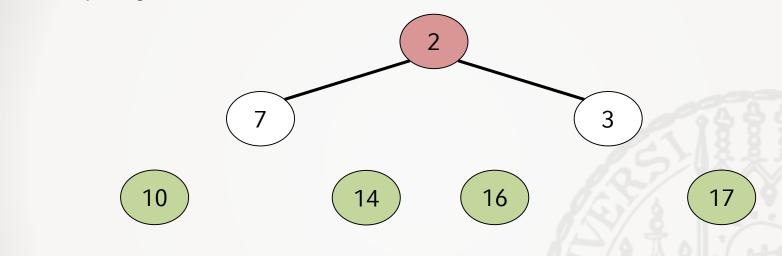
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



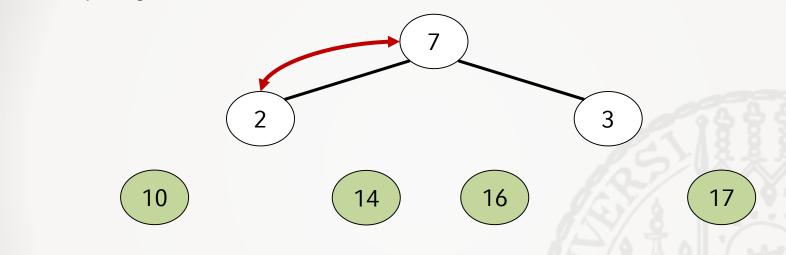
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



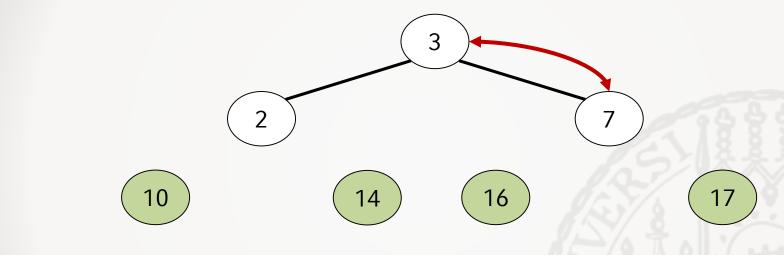
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen



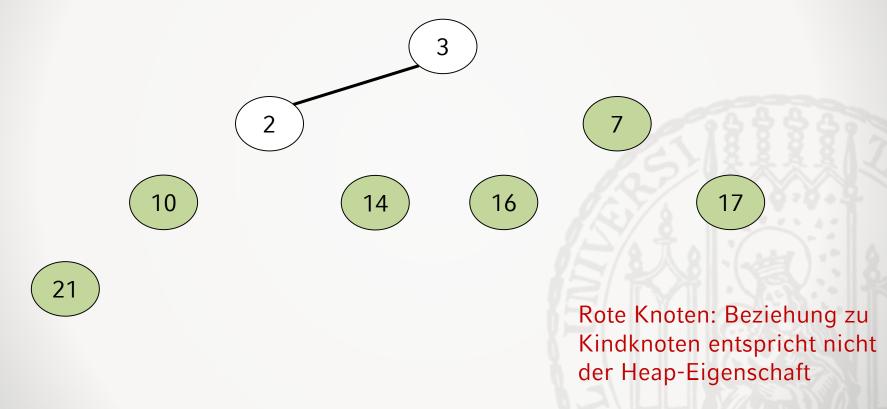
21

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element

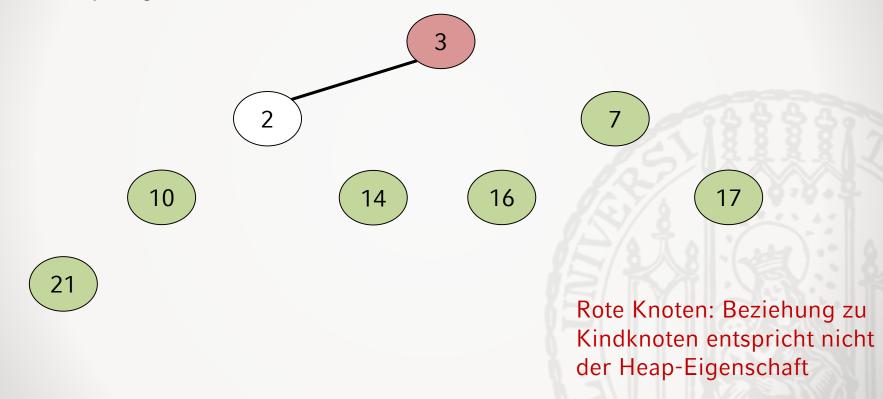


21

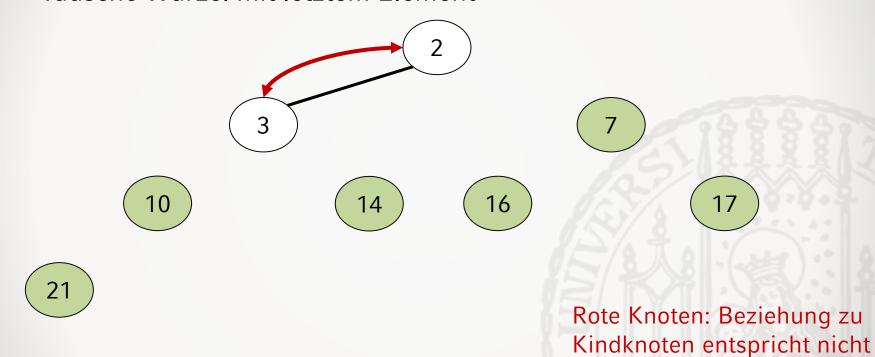
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Heap-Eigenschaft wiederherstellen

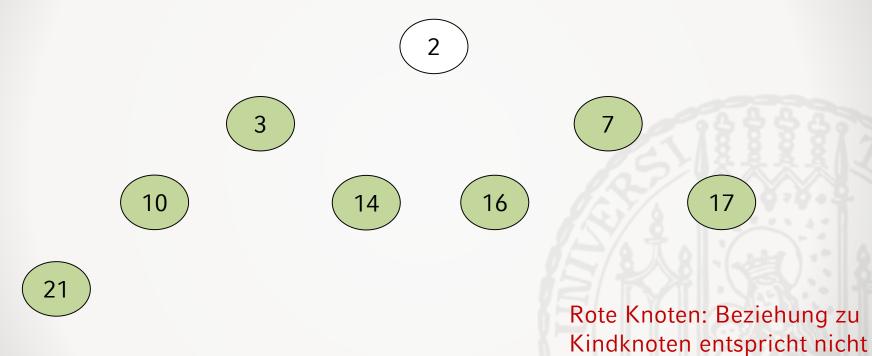


- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Tausche Wurzel mit letztem Element



der Heap-Eigenschaft

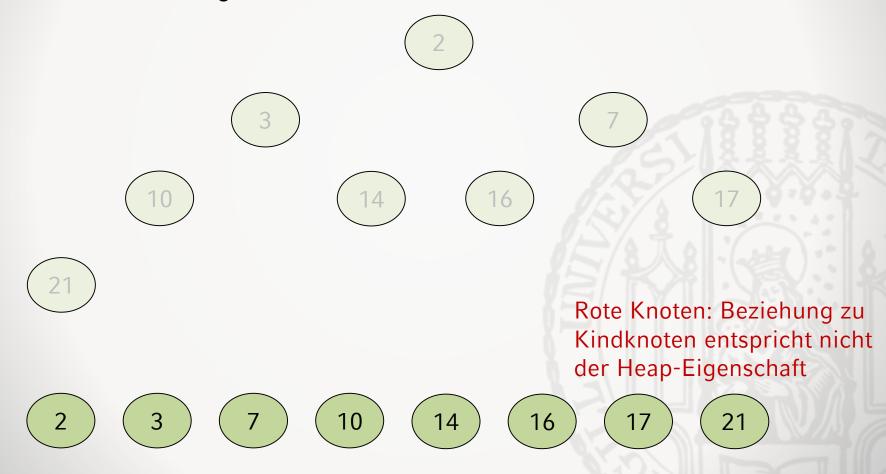
- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Entferne letzten Knoten aus der Struktur



der Heap-Eigenschaft

HeapSort: Beispiel

- Sortiere 10, 14, 7, 17, 3, 21, 2, 16
- Alle Knoten abgearbeitet und Sortieren beendet.



HeapSort: Beispiel mit Arrayeinbettung

10	14	7	17	3	21	2	16
10	14	21	17	3	7	2	16
10	17	21	16	3	7	2	14
21	17	10	16	3	7	2	14
14	17	10	16	3	7	2	21
17	16	10	14	3	7	2	21
2	16	10	14	3	7	17	21
16	14	10	2	3	7	17	21
7	14	10	2	3	16	17	21
14	7	10	2	3	16	17	21
3	7	10	2	14	16	17	21
10	7	3	2	14	16	17	21
2	7	3	10	14	16	17	21
7	2	3	10	14	16	17	21
3	2	7	10	14	16	17	21
2	3	7	10	14	16	17	21

HeapSort: Komplexität

- Überführen der Elemente in einen Binärbaum: O(n)
- Herstellen der Heap-Eigenschaft (Heapify)
 - Jeder Knoten könnte versickern.
 - Versickern geht maximal $\log_2 n$ tief.
 - Damit naiv und grob: $O(\log n n)$
- Für jeden Knoten (weil jeder mal Wurzel wird)
 - Tauschen mit dem letzten Knoten O(1)
 - Heapeigenschaft reparieren, Vertauschungen entlang eines Pfades im Baum: $O(\log n)$
- Insgesamt also $O(n \log n)$

HeapSort: Komplexität Heapaufbau

- Benötigt die Herstellung eines Heaps überhaupt $O(n \log n)$?
- Betrachten wir einen vollständigen Binärbaum mit Höhe h und damit $n = 2^{h+1} 1$ Knoten.
- Wir bestimmen den Aufwand jedes Knotens von den Blättern an bis zur Wurzel.
- Ein Blatt kann nicht versickern und erfüllt immer die Heapeigenschaft \Rightarrow 0 Vertauschungen für 2^h Knoten.
- Auf der nächsten Ebene gibt es 2^{h-1} Knoten, die maximal einmal versickern können.
- Die Wurzel kann schließlich h-mal versickern.

$$T(n) = \sum_{i=0}^{h} (i \cdot 2^{h-i}) = 2^{h} \sum_{i=0}^{h} \frac{i}{2^{i}}$$

HeapSort: Komplexität Heapaufbau (2)

• Kleiner Einschub: Geometrische Reihe (|x| < 1)

$$\sum_{i=0}^{\infty} x^i = \frac{1}{1-x}$$

Beide Seiten ableiten und multiplizieren mit x:

$$\sum_{i=0}^{\infty} ix^i = \frac{x}{(1-x)^2}$$

• Für $x = \frac{1}{2}$ erhalten wir:

$$\sum_{i=0}^{\infty} \frac{i}{2^i} = \sum_{i=0}^{\infty} i \left(\frac{1}{2}\right)^i = \frac{\frac{1}{2}}{\left(1 - \frac{1}{2}\right)^2} = 2$$

HeapSort: Komplexität Heapaufbau (3)

Nun können wir unsere Formel

$$T(n) = \sum_{i=0}^{h} (i \cdot 2^{h-i}) = 2^{h} \sum_{i=0}^{h} \frac{i}{2^{i}}$$

abschätzen, indem wir noch ein paar (unendlich viele) Summanden hinzufügen:

$$2^{h} \sum_{i=0}^{h} \frac{i}{2^{i}} \le 2^{h} \sum_{i=0}^{\infty} \frac{i}{2^{i}} \le 2^{h} 2$$

Damit gilt mit $n = 2^{h+1} - 1$:

$$T(n) \le 2^{h+1} = n + 1 \in O(n)$$

Schranken des Sortierproblems

- Bisher: Sortieralgorithmen haben Komplexität
- Können wir einen Sortieralgorithmus finden, der besser ist als die gezeigten?
- Jetzt: Frage nach der Komplexität des Problems
- Wie groß ist die Anzahl der Schlüsselvergleiche $T_{min}(n)$, um eine nelementige Folge von Schlüsselelementen mit einem beliebigen
 (effizientesten) Algorithmus zu sortieren?
- Existiert $T_{min}(n)$, sodass $T_{min}(n) \le T_A(n)$ für alle Algorithmen A? D.h. jeder denkbare Algorithmus braucht in diesem Fall mindestens $T_{min}(n)$ viele Vergleiche.

Obere Schranke

Betrachten wir beispielsweise MergeSort, so wissen wir bereits:

$$T_{min}(n) \le n \lceil \log_2 n \rceil - n + 1 \in O(n \log n)$$



Untere asymptotische Schranke

- Wir benötigen zusätzlich ein Komplexitätsmaß für eine untere asymptotische Schranke.
- Erinnerung:

$$O(f) = \{g: \mathbb{N} \to \mathbb{R} \mid \exists c > 0 \ \exists n_0 > 0 \ \forall n \ge n_0 : |g(n)| \le c \cdot |f(n)| \}$$

Analog zu O(f) definieren wir:

$$\Omega(f) = \{g: \mathbb{N} \to \mathbb{R} \mid \exists c > 0 \ \exists n_0 > 0 \ \forall n \ge n_0 : |g(n)| \ge c \cdot |f(n)| \}$$

Permutationen

• Gegeben sei eine *n*-elementige Folge

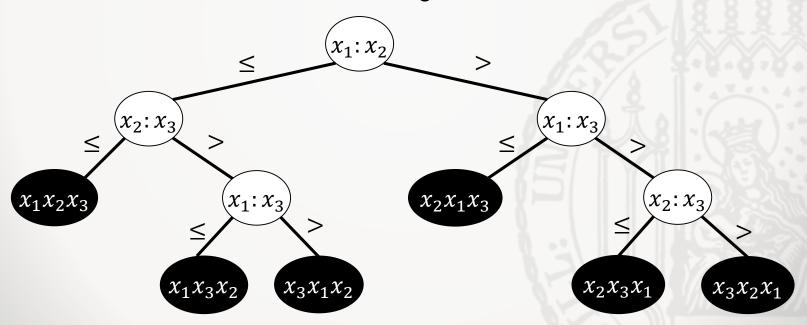
$$x_1, x_2, \dots, x_n$$

- Sei $X = \{x_1, x_2, ..., x_n\}$. Eine bijektive Abbildung $\pi: X \to X$ ist eine Permutation.
- Zum Beispiel ist 3,6,2 eine Permutation von 6,2,3 mit $\pi(3) = 6$, $\pi(6) = 2$ und $\pi(2) = 3$.
- Es gibt n! viele Permutationen auf X.
- Sortieren ist die Auswahl einer Permutation der Folge mit $\pi(x_1) \le \pi(x_2) \le \cdots \le \pi(x_n)$

Entscheidungsbaum

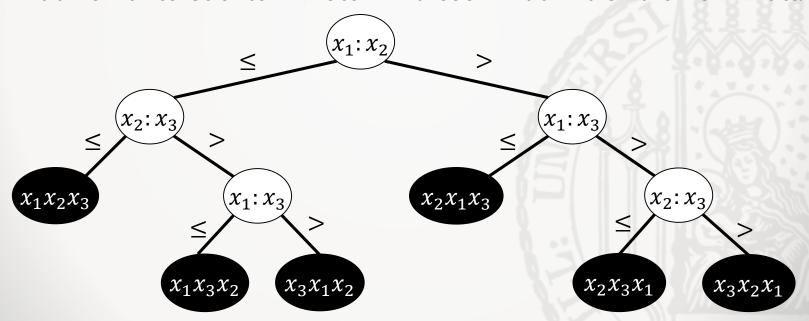
- Der Ablauf eines nur auf Vergleichen basierenden Sortieralgorithmus kann durch einen Entscheidungsbaum dargestellt werden.
- Der folgende binäre Entscheidungsbaum "sortiert" eine 3elementige Folge $x_1x_2x_3$.

Da 3! = 6, muss der Entscheidungsbaum 6 Blätter besitzen.



Entscheidungsreihenfolge von Sortieralgorithmen

- Das Entscheidungsbaummodell stellt unabhängig vom Algorithmus alle möglichen Ausgänge dar.
- Sortieralgorithmen müssen auf dieser Abstraktion das Ergebnis (= das Blatt mit der gesuchten Permutation) erreichen.
- Sie unterscheiden sich durch die Suchstrategie und damit dem Pfad von untersuchten Knoten in diesem Baum bis zu einem Blatt.



Untere Schranke für den Worst-Case

- Die Anzahl der Vergleiche im Worst-Case eines Algorithmus entspricht der Länge des längsten Weges im Entscheidungsbaum.
- Dies wiederum ist die Höhe des Entscheidungsbaums.
- Der Entscheidungsbaum habe Höhe h und b Blätter.
- Wir wissen:
 - Jede Permutation ist als Blatt erreichbar $\Rightarrow n! \leq b$
 - Ein Baum der Höhe h hat maximal 2^h Blätter $\Rightarrow b \leq 2^h$

$$2^{h} \ge b \ge n! \Rightarrow h \ge \log_{2} n! \ge \log_{2} \left(\frac{n}{e}\right)^{n}$$
$$= n \log_{2} n - n \log_{2} e \in \Omega(n \log n)$$

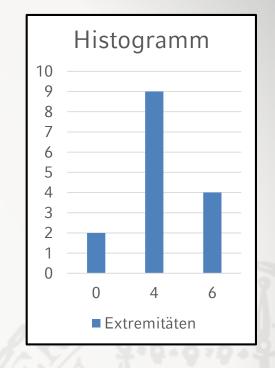
• Damit folgt der zentrale Satz: Jedes vergleichsbasierte Sortierverfahren benötigt $\Omega(n \log n)$ Vergleiche im Worst-Case.

CountingSort

- Angenommen, die Schlüssel sind darstellbar als ganzzahlige Werte im Bereich 0, ..., m-1.
- Beispiel: Sortieren aller eingeschriebener Studenten anhand Studiensemesters 1 ... 20.
- Wir können ein Histogramm erstellen und zählen für jeden Schlüsselwert seine Häufigkeit.
- Diese Häufigkeit liefert die Position für jeden Record.
- Bewege nun die Records an ihre errechnete Position.

CountingSort: Beispiel

- Beispiel: Sortiere Tiere anhand der Anzahl ihrer Extremitäten.
 Ameise, Bär, Dachs, Elefant, Fliege, Giraffe, Hase, Karpfen, Löwe, Mistkäfer, Schlange, Tiger, Uhu, Wespe, Zebra
- Mögliche Kategorien: 0, 4, 6
- Damit liegen die Bereiche im Zielarray fest:





• Ein weiterer Durchlauf reicht, um die einzelnen Schlüssel an die passende Position zu schreiben:



CountingSort: Komplexität

- Es werden n Schlüssel sortiert mit m verschiedenen Schlüsselwerten
- Initialisierung des Histogramms $\rightarrow O(m)$
- Zählen der Schlüssel, Schleife über alle Schlüssel $\rightarrow O(n)$
- Bestimmung der Adressen für alle m Werte $\rightarrow O(m)$
- Zusammenstellung des finalen sortierten Arrays O(n)
- Insgesamt: $O(m+n) = O(\max(m,n))$
- Für kleine m ist CountingSort besser als vorherige Verfahren?
 - Untere Schranke $O(n \log n)$ beruht auf der Anzahl der Vergleiche.
 - CountingSort ist nicht vergleichsbasiert, sondern adressbasiert.

Modernes effizientes Sortieren

- Java: Arrays.sort() nutzt "Dual-Pivot Quicksort"
 - Wähle zwei Pivots und splitte in drei Teile
- Vergleichsbasierte Methoden oft als Hybridverfahren
 - IntroSort sortiert wie QuickSort, außer eine Bewertung im Teilschritt prognostiziert den Worst-Case, dann wird HeapSort genutzt
- Python: Timsort
 - Hybrid aus MergeSort und InsertionSort
 - Findet vorsortierte Teilstücke und sortiert bloß dazwischen
- Oft anwendungsspezifisch:
 - Bei großer Wahrscheinlichkeit von Vorsortierung ist Best-Case wichtiger als Worst-Case
- Paralleles Sortieren ebenfalls möglich. Keine Änderung der Komplexität, aber Beschleunigung durch zeitgleiches Rechnen.

Fazit: Sortieren

- Einfache Sortieralgorithmen (BubbleSort, SelectionSort, InsertionSort):
 - Einfache Implementierung
 - Im schlimmsten Fall unnötig viele Vergleiche $\Rightarrow O(n^2)$
- Bessere Suchverfahren (QuickSort, MergeSort, HeapSort):
 - Komplexere Implementierung
 - Nutzen Datenstrukturen zur Verwaltung von Wissen über vorherige Vergleiche
 - Daher kann Sortieren in $O(n \log n)$ durchgeführt werden.
- $O(n \log n)$ viele Vergleiche werden mindestens benötigt bei vergleichsbasierten Verfahren.